

ALMA MATER STUDIORUM · UNIVERSITÀ DI BOLOGNA

SCUOLA DI SCIENZE

Corso di Laurea Magistrale in Matematica

Metodi numerici proiettivi
con componente probabilistica
per equazioni matriciali lineari

Tesi di Laurea in Analisi Numerica

Relatore:

Chiar.ma Prof.

Valeria Simoncini

Presentata da:

Eugenio Turchet

Anno Accademico 2023-2024

Ringraziamenti

Prima di procedere con la trattazione, desidero dedicare qualche parola a chi mi è stato vicino durante questo percorso.

Un sentito ringraziamento va innanzitutto alla mia relatrice, la Prof.ssa Valeria Simoncini, per la sua costante disponibilità, per la tempestività con cui ha risposto a ogni mia richiesta e per i preziosi consigli che mi hanno guidato nell'elaborazione di questo lavoro. Sono profondamente grato per l'opportunità di intraprendere questo progetto, che mi ha permesso di crescere sotto molteplici punti di vista ed espandere le mie conoscenze.

Un grazie speciale va alla mia famiglia: a mia madre Blerina, a mio padre Andrea e al mio fratellino Marco. Senza il loro sostegno incondizionato, non sarei mai arrivato fino a questo traguardo. Grazie per essere sempre stati al mio fianco, soprattutto nei momenti di difficoltà, e per avermi permesso di seguire le mie aspirazioni con fiducia e serenità.

Ringrazio di cuore Lorenzo, che nonostante la distanza è stato sempre presente con il suo affetto e supporto.

Un ringraziamento particolare va a Gaia, che mi ha accompagnato in questo periodo complesso, aiutandomi nella revisione dell'elaborato e condividendo con me la gioia per i risultati raggiunti.

Infine, un grazie a tutti coloro che, anche se non menzionati direttamente, hanno lasciato un segno lungo questo cammino.

Introduzione

Negli ultimi decenni, la risoluzione efficiente di equazioni matriciali lineari è diventata cruciale in numerose applicazioni scientifiche e ingegneristiche [28]. In questo ambito, i metodi basati sugli spazi di Krylov hanno giocato un ruolo centrale. Introdotti da Y. Saad negli anni '90 [25], questi metodi utilizzano sottospazi iterativi per costruire approssimazioni di rango basso alla soluzione del problema matriciale. Il vantaggio principale dei metodi di Krylov risiede nella loro capacità di sfruttare le proprietà strutturali delle matrici sparse, riducendo così il costo computazionale in problemi di grandi dimensioni. Questi metodi sono diventati una delle tecniche più versatili per risolvere equazioni lineari, problemi agli autovalori e sistemi differenziali.

Uno dei passaggi chiave nei metodi di Krylov è l'ortogonalizzazione della base. Durante la costruzione del sottospazio di Krylov, ogni nuovo vettore generato può essere linearmente dipendente rispetto a quelli già esistenti, rendendo meno efficace la creazione del sottospazio. Per evitare la perdita di indipendenza lineare tra i vettori, che porterebbe a soluzioni meno accurate o inefficaci, si esegue l'ortogonalizzazione. Questo passaggio assicura che la base di Krylov resti ortogonale o quasi ortogonale, migliorando la stabilità numerica e la precisione dell'approssimazione. Tuttavia, l'ortogonalizzazione, in particolare con tecniche come il metodo di Gram-Schmidt, ha un costo computazionale significativo, che cresce con il numero di iterazioni.

Per far fronte a questo problema, sono stati sviluppati i metodi di Krylov troncati, che riducono l'ampiezza dello spazio di ricerca approssimando solo una parte della base ortogonale. Tali tecniche, pur riducendo il costo del calcolo, soffrono di problemi di ritardo di convergenza o stagnazione, specialmente nei contesti più complessi, come le equazioni di Sylvester. Nel caso di quest'ultima equazione, i metodi troncati non sono

stati usati in modo autonomo, poiché tendono a non convergere efficacemente ([30]).

Recentemente, è stata proposta una tecnica, nota come randomized sketching, per superare queste limitazioni. Lo sketching consiste nel proiettare i dati originali in uno spazio di dimensioni ridotte tramite una trasformazione casuale, mantenendo le proprietà essenziali del problema originale. Questa tecnica è stata dimostrata efficace per problemi di base come il calcolo degli autovalori, la risoluzione di sistemi lineari e la minimizzazione ai minimi quadrati [6, 12, 19, 20]. In particolare, Palitta, Schweitzer e Simoncini [21] hanno applicato lo sketching alle equazioni di Sylvester, combinandolo con i metodi di Krylov troncati, riuscendo a migliorare il tasso di convergenza senza incrementare significativamente i costi computazionali.

Il contributo principale di questo lavoro risiede nell'estensione di queste tecniche per affrontare un problema molto più complesso dell'equazione di Sylvester. Ci concentriamo su un'equazione più generale:

$$\mathbf{A}_1 \mathbf{X} \mathbf{B}_1^\top + \mathbf{A}_2 \mathbf{X} \mathbf{B}_2^\top + \cdots + \mathbf{A}_m \mathbf{X} \mathbf{B}_m^\top = \mathbf{C}_1 \mathbf{C}_2^\top, \quad (1)$$

dove le matrici $\mathbf{A}_i \in \mathbb{R}^{n \times n}$ e $\mathbf{B}_j \in \mathbb{R}^{m \times m}$ sono simmetriche, definite positive e sparse, e $\mathbf{X} \in \mathbb{R}^{n \times n}$ è la matrice soluzione da determinare. Per questo tipo di problema, i metodi proiettivi classici non risultano più efficienti. L'obiettivo è generalizzare la combinazione di sketching e troncamento per evitare la generazione di uno spazio proiettivo troppo grande, preservando al contempo l'efficacia e la velocità di convergenza del metodo. Inizialmente si analizzerà un caso più semplice, ovvero:

$$\mathbf{A} \mathbf{X} + \mathbf{X} \mathbf{A}^\top + \mathbf{M} \mathbf{X} \mathbf{M}^\top = \mathbf{C} \mathbf{C}^\top \quad (2)$$

dove $\mathbf{A} \in \mathbb{R}^{n \times n}$, $\mathbf{M} \in \mathbb{R}^{n \times n}$ sono matrici simmetriche definite positive sparse, $\mathbf{C} \in \mathbb{R}^n$ e $\mathbf{X} \in \mathbb{R}^{n \times n}$ è soluzione incognita dell'equazione (2). Nel capitolo 1, verranno introdotti alcuni concetti preliminari, come le operazioni matriciali e l'operatore di Kronecker, oltre a una discussione sulla formulazione generale del problema. Nel Capitolo 2, si analizzeranno gli spazi di Krylov e i metodi di proiezione classici. Il Capitolo 3 sarà dedicato alla costruzione di algoritmi basati sugli ϵ -sottospazi di embedding e sketching, con una discussione approfondita delle loro proprietà. Infine, nei capitoli successivi,

verranno presentati i risultati numerici ottenuti su diversi set di dati, confrontando l'approccio proposto con metodi già esistenti.

Indice

1	Equazioni matriciali lineari	12
1.1	Alcune operazioni matriciali e vettoriali	12
1.2	Equazioni matriciali lineari	16
2	Metodi proiettivi e spazi di Krylov	18
2.1	Prime definizioni	18
2.2	Sottospazi di Krylov	20
2.3	Metodo di Arnoldi	23
2.4	FOM	27
2.5	GMRES	29
2.5.1	Algoritmo di base	29
2.5.2	Aspetti implementativi	31
2.5.3	Condizioni di arresto	37
2.6	Convergenza di GMRES: cenni	37
3	ϵ-sottospazio di embedding	40
3.1	Sottospazio di embedding	40
3.2	Trasformate di Johnson-Lindenstrauss	42
3.3	Trasformate di Johnson-Lindenstrauss rapide: Cenni	45
4	Metodo Sketched ed Arnoldi troncato su spazi di Krylov per equazioni matriciali	48
4.1	Approccio iniziale	48

4.2	Spazi di proiezione e relazione di Arnoldi troncata	50
4.3	Sketching incontra Krylov	52
4.4	Calcolo del residuo	54
4.5	L'algoritmo	58
4.6	Esperimenti numerici	60
5	Metodo Sketched ed Arnoldi troncato su spazi di Krylov: caso multitermine	64
5.1	Metodo con sottospazi di Krylov razionali	64
5.2	Metodo sketched Galerkin: caso multitermine	68
5.3	Esperimenti numerici	69
	Bibliografia	81

Notazioni

Si introducono alcune notazioni che verranno utilizzate nel corso della trattazione.

Notazioni matriciali

Data una matrice $\mathbf{A} \in \mathbb{R}^{m \times n}$ denotiamo con:

- $A_{i,j}$ (oppure con $a_{i,j}$) l'elemento sulla i -esima riga e sulla j -esima colonna;
- $\mathbf{A}_{i,:}$ l' i -esima riga;
- $\mathbf{A}_{:,j}$ la j -esima colonna;
- $\text{Ker}(\mathbf{A}) = \{x \in \mathbb{R}^n \mid \mathbf{A}x = 0\}$ il nucleo (o kernel) di $\mathbf{A}$.
- $\text{Im}(\mathbf{A}) = \{y \in \mathbb{R}^m \mid \exists x \in \mathbb{R}^n, \mathbf{A}x = y\}$ l'immagine (o range) di $\mathbf{A}$;
- $\sigma(\mathbf{A}) = \{\lambda \in \mathbb{C} \mid \exists x \in \mathbb{C}^n \setminus \{0\}, \mathbf{A}x = \lambda x\}$ lo spettro, l'insieme degli autovalori della matrice $\mathbf{A}$, nel caso sia quadrata ($m = n$);
- $\mathbf{A}^\top$ (rispettivamente $\mathbf{A}^*$) la matrice trasposta (rispettivamente trasposta coniugata) di $\mathbf{A}$.

Definiamo, inoltre:

- La norma indotta p -esima di $\mathbf{A}$:

$$\|\mathbf{A}\|_p := \sup_{x \neq 0} \frac{\|\mathbf{A}x\|_p}{\|x\|_p} = \sup_{\|x\|_p=1} \|\mathbf{A}x\|_p$$

Qualora p non fosse specificato si considera implicitamente $\|\mathbf{A}\|_2$.

- La norma di Frobenius di $\mathbf{A}$:

$$\|\mathbf{A}\|_F := \sqrt{\sum_{i,j} |A_{i,j}|^2}$$

- Il numero di condizionamento per $\mathbf{A} \in \mathbb{R}^{n \times n}$ non singolare:

$$\kappa_\gamma(\mathbf{A}) := \|\mathbf{A}\|_\gamma \|\mathbf{A}^{-1}\|_\gamma$$

per una norma matriciale $\|\cdot\|_\gamma$. Quando non sarà specificato γ si intenderà implicitamente $\kappa_2(\mathbf{A})$.

- La norma energia di un vettore $x \in \mathbb{R}^n$ rispetto a una matrice $\mathbf{A} \in \mathbb{R}^{n \times n}$ simmetrica definita positiva:

$$\|x\|_{\mathbf{A}} := \sqrt{x^\top \mathbf{A} x}$$

- $\text{Im}(\mathbf{A})^\perp = \{y \in \mathbb{R}^m \mid \langle y, \mathbf{A}x \rangle = 0 \ \forall x \in \mathbb{R}^m\}$ dove $\langle \cdot, \cdot \rangle$ è il prodotto scalare indotto dalla norma euclidea $\|\cdot\|_2$.
- Scriviamo, infine, $\mathbf{I}_n$ (a volte Id) per la matrice identità $n \times n$ ed $e_i \in \mathbb{R}^n$ per la sua i -esima colonna.

Notazioni su applicazioni lineari

Sia $\mathfrak{F} : \mathbb{R}^n \rightarrow \mathbb{R}^m$ un'applicazione lineare. Denotiamo con:

- $\text{Ker}(\mathfrak{F}) = \{x \in \mathbb{R}^n \mid \mathfrak{F}(x) = 0\}$ il nucleo (o kernel) di $\mathfrak{F}$.
- $\text{Im}(\mathfrak{F}) = \{y \in \mathbb{R}^m \mid \exists x \in \mathbb{R}^n, \mathfrak{F}(x) = y\}$ l'immagine (o range) di $\mathfrak{F}$;
- $\text{Im}(\mathfrak{F})^\perp = \{y \in \mathbb{R}^m \mid \langle y, \mathfrak{F}(x) \rangle = 0 \ \forall x \in \mathbb{R}^n\}$ dove $\langle \cdot, \cdot \rangle$ è il prodotto scalare indotto dalla norma euclidea $\|\cdot\|_2$.

Notazioni Ω , O , Θ

Sia $k \in \mathbb{N}$ un parametro e $d \in \mathbb{R}$ fissato, diremo che:

- $k = \Omega(d)$ se esistono due costanti $c, k_0 > 0$ tali che

$$k > cd \quad \forall k \geq k_0.$$

- $k = O(d)$ se esistono due costanti $c, k_0 > 0$ tali che

$$k < cd \quad \forall k \geq k_0.$$

- $k = \Theta(d)$ se esistono tre costanti $c_0, c_1, k_0 > 0$ tali che

$$c_0 d < k < c_1 d \quad \forall k \geq k_0.$$

Capitolo 1

Equazioni matriciali lineari

In questo capitolo verranno discusse le equazioni matriciali lineari. Dopo aver definito alcune operazioni matriciali e vettoriali utili per la trattazione, si darà la definizione di equazione matriciale lineare e alcune condizioni per l'esistenza e l'unicità della soluzione. Il materiale qui contenuto è tratto da [14] e [15].

1.1 Alcune operazioni matriciali e vettoriali

In questa sezione verranno introdotte alcune operazioni non banali tra matrici e tra vettori con alcune conseguenti proprietà.

Definizione 1.1.1. (Impilamento di matrici). L'impilamento di due matrici $\mathbf{A} \in \mathbb{R}^{m \times n}$ e $\mathbf{B} \in \mathbb{R}^{p \times q}$ di opportune dimensioni è la matrice:

$$[\mathbf{A}; \mathbf{B}] := \begin{bmatrix} \mathbf{A} \\ \mathbf{B} \end{bmatrix}$$

In particolare $\mathbf{A}$ e $\mathbf{B}$ devono avere lo stesso numero di colonne, ossia $n = q$.

Definizione 1.1.2. (Prodotto di Kronecker). Data una matrice $\mathbf{A} = (a_{i,j}) \in \mathbb{R}^{m \times n}$ e

una matrice $\mathbf{B} \in \mathbb{R}^{p \times q}$ definiamo il prodotto di Kronecker tra $\mathbf{A}$ e $\mathbf{B}$ come:

$$\mathbf{A} \otimes \mathbf{B} := (a_{i,j} \mathbf{B})_{\substack{1 \leq i \leq m \\ 1 \leq j \leq n}} = \begin{bmatrix} a_{1,1} \mathbf{B} & a_{1,2} \mathbf{B} & \cdots & a_{1,n} \mathbf{B} \\ a_{2,1} \mathbf{B} & a_{2,2} \mathbf{B} & \cdots & a_{2,n} \mathbf{B} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m,1} \mathbf{B} & a_{m,2} \mathbf{B} & \cdots & a_{m,n} \mathbf{B} \end{bmatrix} \in \mathbb{R}^{mp \times nq}$$

dove la seconda e terza scrittura rappresentano una matrice a blocchi.

Proposizione 1.1.1. Date le matrici quadrate $\mathbf{A}_1, \mathbf{A}_2 \in \mathbb{R}^{m \times m}$ e $\mathbf{B}_1, \mathbf{B}_2 \in \mathbb{R}^{n \times n}$, si ha:

$$(\mathbf{A}_1 \otimes \mathbf{B}_1)(\mathbf{A}_2 \otimes \mathbf{B}_2) = \mathbf{A}_1 \mathbf{A}_2 \otimes \mathbf{B}_1 \mathbf{B}_2.$$

Corollario 1.1.1. Siano $\mathbf{A} \in \mathbb{R}^{m \times m}$, $\mathbf{B} \in \mathbb{R}^{n \times n}$. Allora

1. $\mathbf{A} \otimes \mathbf{B} = (\mathbf{A} \otimes \mathbf{I}_n)(\mathbf{I}_m \otimes \mathbf{B}) = (\mathbf{I}_m \otimes \mathbf{B})(\mathbf{A} \otimes \mathbf{I}_n)$
2. $(\mathbf{A} \otimes \mathbf{B})^{-1} = \mathbf{A}^{-1} \otimes \mathbf{B}^{-1}$ (con $\mathbf{A}$ e $\mathbf{B}$ non singolari)

Proposizione 1.1.2. Siano $\mathbf{A} \in \mathbb{R}^{m \times m}$, $\mathbf{B} \in \mathbb{R}^{n \times n}$ matrici triangolari inferiori (rispettivamente superiori), allora $\mathbf{A} \otimes \mathbf{B}$ è una matrice triangolare superiore (rispettivamente superiore).

Dimostrazione. Dalla definizione di prodotto Kronecker e dalla struttura delle matrici si ricava la tesi. $\square$

Proposizione 1.1.3. Siano $\mathbf{A} \in \mathbb{R}^{m \times m}$, $\mathbf{B} \in \mathbb{R}^{n \times n}$ due matrici simmetriche, allora $\mathbf{A} \otimes \mathbf{B}$ è simmetrica.

Dimostrazione. Dalla definizione di prodotto di Kronecker abbiamo:

$$\mathbf{A} \otimes \mathbf{B} = \begin{bmatrix} a_{1,1} \mathbf{B} & a_{1,2} \mathbf{B} & \cdots & a_{1,m} \mathbf{B} \\ a_{2,1} \mathbf{B} & a_{2,2} \mathbf{B} & \cdots & a_{2,m} \mathbf{B} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m,1} \mathbf{B} & a_{m,2} \mathbf{B} & \cdots & a_{m,m} \mathbf{B} \end{bmatrix} \in \mathbb{R}^{mn \times mn}$$

$\mathbf{A}$ è simmetrica, ossia $a_{i,j} = a_{j,i}$ per $i, j = 1, 2, \dots, m$, allora $\mathbf{A} \otimes \mathbf{B}$ è simmetrica a blocchi. Poichè, inoltre, $\mathbf{B}$ è simmetrica per ipotesi, $\mathbf{A} \otimes \mathbf{B}$ è globalmente simmetrica. $\square$

Teorema 1.1.1. Siano $\mathbf{A} \in \mathbb{R}^{m \times m}$, $\mathbf{B} \in \mathbb{R}^{n \times n}$, allora valgono le seguenti proprietà:

1. $\forall \lambda \in \sigma(\mathbf{A} \otimes \mathbf{B}), \lambda = \lambda_A \lambda_B$ con $\lambda_A \in \sigma(\mathbf{A})$ e $\lambda_B \in \sigma(\mathbf{B})$.
2. $\forall \lambda \in \sigma((\mathbf{I}_n \otimes \mathbf{A}) + (\mathbf{B} \otimes \mathbf{I}_m)), \lambda = \lambda_A + \lambda_B$ con $\lambda_A \in \sigma(\mathbf{A})$ e $\lambda_B \in \sigma(\mathbf{B})$

Dimostrazione. Considerando la decomposizione di Jordan di $\mathbf{A}$ e $\mathbf{B}$ abbiamo:

$$\mathbf{PAP}^{-1} = \mathbf{J}_1, \quad \mathbf{QBQ}^{-1} = \mathbf{J}_2,$$

con $\mathbf{P} \in \mathbb{C}^{m \times m}$ e $\mathbf{Q} \in \mathbb{C}^{n \times n}$ matrici invertibili, $\mathbf{J}_1$ e $\mathbf{J}_2$ matrici in forma di Jordan. Chiaramente $\mathbf{J}_1$ e $\mathbf{J}_2$ sono matrici triangolari superiori con elementi $\lambda_1, \lambda_2, \dots, \lambda_m$ e $\mu_1, \mu_2, \dots, \mu_n$ sulla diagonale rispettivamente.

Dalla Proposizione 1.1.3 si ricava che $\mathbf{J}_1 \otimes \mathbf{J}_2$ è triangolare superiore e dalla Definizione 1.2 si ha che gli elementi sulla diagonale sono $\mu_s \lambda_r$ per $r = 1, 2, \dots, m, s = 1, 2, \dots, n$ e corrispondono agli autovalori data la struttura triangolare. Basta ora mostrare che $(\mathbf{J}_1 \otimes \mathbf{J}_2)$ e $(\mathbf{A} \otimes \mathbf{B})$ hanno gli stessi autovalori. Dalla Proposizione 1.1.1 e dal Corollario 1.1.2 abbiamo:

$$\begin{aligned} \mathbf{J}_1 \otimes \mathbf{J}_2 &= \mathbf{PAP}^{-1} \otimes \mathbf{QBQ}^{-1} = (\mathbf{P} \otimes \mathbf{Q})(\mathbf{A} \otimes \mathbf{B})(\mathbf{P}^{-1} \otimes \mathbf{Q}^{-1}) \\ &= (\mathbf{P} \otimes \mathbf{Q})(\mathbf{A} \otimes \mathbf{B})(\mathbf{P} \otimes \mathbf{Q})^{-1} \end{aligned}$$

Pertanto $\mathbf{J}_1 \otimes \mathbf{J}_2$ e $\mathbf{A} \otimes \mathbf{B}$ sono simili e hanno gli stessi autovalori. Il punto 2 è una diretta conseguenza del punto 1. $\square$

Proposizione 1.1.4. Se $\mathbf{A} \in \mathbb{R}^{m \times m}$, $\mathbf{B} \in \mathbb{R}^{n \times n}$ sono matrici simmetriche semidefinite positive, allora $\mathbf{A} \otimes \mathbf{B} \in \mathbb{R}^{mn \times mn}$ è simmetrica semidefinita positiva. Nel caso in cui $\mathbf{A}$ e $\mathbf{B}$ siano entrambe definite positive, $\mathbf{A} \otimes \mathbf{B}$ è definita positiva.

Dimostrazione. La simmetria è ottenuta dalla Proposizione 1.1.3. Nel caso in cui $\mathbf{A}$ e $\mathbf{B}$ siano semidefinite positive allora dal Teorema 1.1.1 gli autovalori di $\mathbf{A} \otimes \mathbf{B}$ sono

della forma $\lambda = \lambda_A \lambda_B$ con $\lambda_A \in \sigma(\mathbf{A})$ e $\lambda_B \in \sigma(\mathbf{B})$. Ma $\lambda_A \geq 0, \forall \lambda_A \in \sigma(\mathbf{A})$ e $\lambda_B \geq 0, \forall \lambda_B \in \sigma(\mathbf{B})$ per ipotesi, da cui la tesi. Analogo il caso in cui $\mathbf{A}$ e $\mathbf{B}$ siano definite positive $\square$

Definizione 1.1.3. (Vettorizzazione). Sia $\mathbf{A} = [A_{:,1}, A_{:,2}, \dots, A_{:,n}] \in \mathbb{R}^{m \times n}$, la sua vettorizzazione è il vettore dato dalle colonne di $\mathbf{A}$ impilate una sopra l'altra, ossia:

$$Vec(\mathbf{A}) = [A_{:,1}; A_{:,2}; \dots; A_{:,n}] = \begin{bmatrix} A_{:,1} \\ A_{:,2} \\ \vdots \\ A_{:,n} \end{bmatrix}$$

Il prodotto di Kronecker e la vettorizzazione sono legati da questa importante proprietà.

Proposizione 1.1.5. Siano $\mathbf{A} \in \mathbb{R}^{m \times m}$, $\mathbf{B} \in \mathbb{R}^{n \times n}$ e $\mathbf{X} \in \mathbb{R}^{m \times n}$, allora:

$$Vec(\mathbf{AXB}) = (\mathbf{B}^\top \otimes \mathbf{A})Vec(\mathbf{X})$$

Dimostrazione. Per $j = 1, 2, \dots, n$, la j -esima colonna di $\mathbf{AXB}$ è:

$$\begin{aligned} (\mathbf{AXB})_{:,j} &= \sum_{k=1}^n b_{k,j} (\mathbf{AX})_{:,k} \\ &= \sum_{k=1}^n (b_{k,j} \mathbf{A}) \mathbf{X}_{:,k} \\ &= [b_{1,j} \mathbf{A} \quad b_{2,j} \mathbf{A} \quad \dots \quad b_{n,j} \mathbf{A}] \begin{bmatrix} \mathbf{X}_{:,1} \\ \mathbf{X}_{:,2} \\ \vdots \\ \mathbf{X}_{:,n} \end{bmatrix} \\ &= [b_{1,j} \mathbf{A} \quad b_{2,j} \mathbf{A} \quad \dots \quad b_{n,j} \mathbf{A}] Vec(\mathbf{X}) \\ &= (\mathbf{B}^\top \otimes \mathbf{A}) Vec(\mathbf{X}) \end{aligned}$$

da cui la tesi. $\square$

1.2 Equazioni matriciali lineari

Definizione 1.2.1. (Equazione matriciale lineare). Un'equazione matriciale lineare con matrici coefficiente $\mathbf{A}_1, \mathbf{A}_2, \dots, \mathbf{A}_p \in \mathbb{R}^{m \times m}$ e $\mathbf{B}_1, \mathbf{B}_2, \dots, \mathbf{B}_p \in \mathbb{R}^{n \times n}$ e con matrice di termine noto $\mathbf{C} \in \mathbb{R}^{m \times n}$ è una scrittura formale del tipo:

$$\mathbf{A}_1 \mathbf{X} \mathbf{B}_1 + \mathbf{A}_2 \mathbf{X} \mathbf{B}_2 + \dots + \mathbf{A}_p \mathbf{X} \mathbf{B}_p = \mathbf{C} \quad (1.1)$$

con $\mathbf{X} \in \mathbb{R}^{m \times n}$ incognita.

Definizione 1.2.2. (Soluzione di un'equazione matriciale lineare). $\tilde{\mathbf{X}} \in \mathbb{R}^{m \times n}$ è detta soluzione di (2.1) se soddisfa l'equazione.

Teorema 1.2.1. (Formulazione vettoriale di un'equazione matriciale lineare) Una scrittura alternativa dell'equazione matriciale lineare (1.1) è:

$$\mathbf{G}x = c \quad (1.2)$$

dove $\mathbf{G} = \mathbf{B}_1^\top \otimes \mathbf{A}_1 + \mathbf{B}_2^\top \otimes \mathbf{A}_2 + \dots + \mathbf{B}_p^\top \otimes \mathbf{A}_p$, $x = \text{Vec}(\mathbf{X})$ e $c = \text{Vec}(\mathbf{C})$

Dimostrazione. Dalla Proposizione 2.1.1 abbiamo che $\text{Vec}(\mathbf{A}_j \mathbf{X} \mathbf{B}_j) = (\mathbf{B}_j^\top \otimes \mathbf{A}_j) \text{Vec}(\mathbf{X})$ per $j = 1, 2, \dots, p$. Poichè la vettorizzazione è lineare, abbiamo:

$$\text{Vec}(\mathbf{C}) = \text{Vec}\left(\sum_{j=1}^p \mathbf{A}_j \mathbf{X} \mathbf{B}_j\right) = \sum_{j=1}^p \text{Vec}(\mathbf{A}_j \mathbf{X} \mathbf{B}_j) = \sum_{j=1}^p (\mathbf{B}_j^\top \otimes \mathbf{A}_j) \text{Vec}(\mathbf{X})$$

da cui la tesi. □

Sfruttando la scrittura in (1.2) e utilizzando risultati di algebra lineare (vedi [14] e [15]) è possibile determinare se l'equazione (1.1) è risolubile e se la soluzione è unica.

Proposizione 1.2.1. L'equazione (1.1) è risolubile se $c \in \text{Im}(\mathbf{G})$.

Proposizione 1.2.2. L'equazione (1.1) ha un'unica soluzione se e solo se $\mathbf{G}$ è non singolare

Un caso particolare di equazione matriciale lineare polinomiale è l'equazione di Sylvester.

Definizione 1.2.3. (Equazione di Sylvester). Data una matrice $\mathbf{A} \in \mathbb{R}^{m \times m}$, $\mathbf{B} \in \mathbb{R}^{n \times n}$, $\mathbf{C} \in \mathbb{R}^{m \times n}$, l'equazione di Sylvester è un'equazione matriciale lineare della forma:

$$\mathbf{A}\mathbf{X} + \mathbf{X}\mathbf{B} = \mathbf{C} \quad (1.3)$$

con $\mathbf{X} \in \mathbb{R}^{m \times n}$ incognita.

Anche in questo caso possiamo scrivere l'equazione nella forma (1.2); l'equazione sarà della forma $\mathbf{G}x = c$ con $x = \text{Vec}(\mathbf{X})$, $c = \text{Vec}(\mathbf{C})$ e

$$\mathbf{G} = (\mathbf{I}_n \otimes \mathbf{A}) + (\mathbf{B}^\top \otimes \mathbf{I}_m) \quad (1.4)$$

Teorema 1.2.2. L'equazione (1.3) ha un'unica soluzione se e solo se le matrici $\mathbf{A}$ e $-\mathbf{B}$ non hanno nessun autovalore in comune.

Dimostrazione. Gli autovalori di $\mathbf{G}$ in (1.4) sono per il Teorema 1.1.1 $\lambda_A + \lambda_B \ \forall \lambda_A \in \sigma(\mathbf{A})$ e $\forall \lambda_B \in \sigma(\mathbf{B})$. Dalla prop 1.2.2 l'equazione ha un'unica soluzione se $\mathbf{G}$ è non singolare, ossia se $\mathbf{G}$ non ha autovalori nulli. Pertanto, deve essere:

$$\lambda_A + \lambda_B \neq 0 \ \forall \lambda_A \in \sigma(\mathbf{A}), \ \forall \lambda_B \in \sigma(\mathbf{B})$$

che equivale a chiedere che $\lambda_A \neq -\lambda_B \ \forall \lambda_A \in \sigma(\mathbf{A}), \ \forall -\lambda_B \in \sigma(-\mathbf{B})$. □

Capitolo 2

Metodi proiettivi e spazi di Krylov

In questo capitolo verranno discussi i sottospazi vettoriali di Krylov ed i metodi proiettivi per la risoluzione di un sistema della forma

$$\mathbf{A}x = b \quad \mathbf{A} \in \mathbb{R}^{n \times n}$$

Tutto il materiale è tratto da [25].

2.1 Prime definizioni

Siano dati $\mathbf{A} \in \mathbb{R}^{n \times n}$ non singolare ed il vettore non nullo $b \in \mathbb{R}^n$. L'obiettivo è risolvere il seguente sistema lineare

$$\mathbf{A}x = b$$

Definizione 2.1.1. (Risoluzione per proiezione). Fissati due sottospazi vettoriali K_m e L_m di dimensione m contenuti in $\mathbb{R}^n$ e una stima iniziale della soluzione x_0 allora si considera come stima della soluzione del sistema lineare il vettore x_m tale che

- $x_m \in x_0 + K_m$
- $b - \mathbf{A}x_m \perp L_m$ (condizione di Petrov-Galerkin)

Quando $L_m = K_m$ la seconda condizione viene detta condizione di Galerkin.

Si vuole ora capire come è fatto concretamente un metodo di risoluzione per proiezione. Si è detto che la soluzione approssimata deve avere la forma

$$x_m = x_0 + z_m \quad \text{con} \quad z_m \in K_m$$

Siano dunque $\{v_1, \dots, v_m\}$ una base di K_m e $\{w_1, \dots, w_m\}$ una base di L_m . Allora è possibile esprimere

$$z_m = \sum_{i=1}^m y_i v_i = \mathbf{V}_m y$$

$$\text{con} \quad \mathbf{V}_m = [v_1, v_2, \dots, v_m] \in \mathbb{R}^{n \times m} \quad \text{e} \quad y = [y_1; \dots; y_m] \in \mathbb{R}^m.$$

Inoltre il residuo m -esimo è definito come

$$r_m = b - \mathbf{A}x_m = r_0 - \mathbf{A}z_m.$$

Imporre la condizione di Petrov-Galerkin della Definizione 2.1.1 corrisponde a richiedere che r_m sia ortogonale allo spazio L_m . Scrivendo esplicitamente tale condizione di ortogonalità, si ha

$$\langle w_i, r_0 - \mathbf{A}z_m \rangle = 0 \quad \text{per} \quad i = 1, \dots, m.$$

Sostituendo z_m , è possibile riscrivere tutto in forma matriciale come

$$\mathbf{W}_m^\top (r_0 - \mathbf{A}\mathbf{V}_m y) = 0.$$

Posto che la matrice $\mathbf{W}_m^\top \mathbf{A}\mathbf{V}_m$ sia invertibile, è possibile scrivere i coefficienti come

$$y_m = (\mathbf{W}_m^\top \mathbf{A}\mathbf{V}_m)^{-1} \mathbf{W}_m^\top r_0,$$

da cui si ricava che la soluzione approssimata è la seguente

$$x_m = x_0 + \mathbf{V}_m (\mathbf{W}_m^\top \mathbf{A}\mathbf{V}_m)^{-1} \mathbf{W}_m^\top r_0.$$

2.2 Sottospazi di Krylov

Definizione 2.2.1. (Metodo di Krylov) Un metodo di Krylov è una risoluzione per proiezione dove, fissata la stima iniziale x_0 , si definisce $r_0 = b - \mathbf{A}x_0$ e si sceglie come spazio K_m il sottospazio $\mathcal{K}_m(\mathbf{A}, r_0)$ (sottospazio di Krylov) definito come

$$\mathcal{K}_m(\mathbf{A}, r_0) = \text{span}\{r_0, \mathbf{A}r_0, \mathbf{A}^2r_0, \dots, \mathbf{A}^{m-1}r_0\}.$$

I metodi di Krylov differiscono in base alla scelta dello spazio L_m .

Si analizzeranno brevemente solo due casi: $L_m = K_m$ (metodo di Arnoldi+FOM) ed $L_m = \mathbf{A}K_m$ (GMRES); in realtà sono possibili anche altre scelte che non saranno esaminate.

Osservazione 2.2.1. L'approssimazione data da un metodo di Krylov è della forma

$$\mathbf{A}^{-1}b \approx x_m = x_0 + q_{m-1}(\mathbf{A})r_0$$

Dove q_{m-1} è un polinomio di grado al più $m - 1$.

Per semplicità in seguito assumeremo $\mathbf{A} \in \mathbb{R}^{n \times n}$ e qualsiasi vettore $v \in \mathbb{R}^n$.

Definizione 2.2.2. Fissato un vettore v , il suo polinomio minimo rispetto ad $\mathbf{A}$ è il polinomio monico di grado più basso tale che $p(\mathbf{A})v = 0$.

Osservazione 2.2.2. Per il teorema di Cayley-Hamilton il grado di tale polinomio è minore di $n - 1$, tale grado è detto grado di v rispetto ad $\mathbf{A}$.

Proposizione 2.2.1. Sia μ il grado di v rispetto ad $\mathbf{A}$, allora $\mathcal{K}_\mu$ è invariante sotto l'azione di $\mathbf{A}$ e di conseguenza $\mathcal{K}_m = \mathcal{K}_\mu$ per ogni $m \geq \mu$.

Osservazione 2.2.3. La dimensione degli spazi $\mathcal{K}_m$ è non decrescente e in generale non è detto sia m , per esempio per $m > n$ la dimensione dello spazio non può essere m , altrimenti tale spazio genererebbe $\mathbb{R}^n$ che ha dimensione n . La Proposizione 2.2.3 darà una caratterizzazione della dimensione.

Definizione 2.2.3. (Proiettore)

Un proiettore $\mathfrak{P}$ su un sottospazio vettoriale $K \subseteq \mathbb{R}^n$ è un'applicazione lineare $\mathfrak{P} : \mathbb{R}^n \rightarrow K$ tale che $\mathfrak{P}^2 = \mathfrak{P}$ (quindi l'immagine è invariante). Inoltre se $\ker(\mathfrak{P}) = \text{Im}(\mathfrak{P})^\perp$ diremo che $\mathfrak{P}$ è un proiettore ortogonale.

Proposizione 2.2.2. Sia $\mathfrak{Q}_m$ un proiettore in $\mathcal{K}_m$ (ovvero che ha come immagine un sottospazio di $\mathcal{K}_m$) e sia $\mathbf{A}_m$ la sezione di $\mathbf{A}$ in $\mathcal{K}_m$ ovvero $\mathbf{A}_m = \mathfrak{Q}_m \mathbf{A}|_{\mathcal{K}_m}$ allora per ogni polinomio di grado al più $m - 1$ vale

$$q(\mathbf{A})v = q(\mathbf{A}_m)v.$$

Inoltre, per ogni polinomio di grado al più m

$$\mathfrak{Q}_m q(\mathbf{A})v = q(\mathbf{A}_m)v.$$

Dimostrazione. Si inizia dimostrando che $q(\mathbf{A})v = q(\mathbf{A}_m)v$ per ogni polinomio q di grado $\leq m - 1$. È sufficiente mostrare la proprietà per polinomi monici $q_i(t) \equiv t^i$, $i = 0, \dots, m - 1$. La prova è per induzione. La proprietà è vera per il polinomio $q_0(t) \equiv 1$. Assumiamo che la proprietà sia vera per $q_i(t) \equiv t^i$:

$$q_i(\mathbf{A})v = q_i(\mathbf{A}_m)v.$$

Moltiplicando tale equazione da entrambi i lati per $\mathbf{A}$ si ottiene

$$q_{i+1}(\mathbf{A})v = \mathbf{A}q_i(\mathbf{A}_m)v.$$

Se $i + 1 \leq m - 1$ il vettore a sinistra dell'uguaglianza appartiene a $\mathcal{K}_m$, e perciò se l'equazione sopra è moltiplicata da entrambi i lati da $\mathfrak{Q}_m$, allora

$$q_{i+1}(\mathbf{A})v = \mathfrak{Q}_m \mathbf{A}q_i(\mathbf{A}_m)v.$$

Guardando a destra dell'uguaglianza si osserva che $q_i(\mathbf{A}_m)v$ appartiene a $\mathcal{K}_m$. Quindi,

$$q_{i+1}(\mathbf{A})v = \mathfrak{Q}_m \mathbf{A}|_{\mathcal{K}_m} q_i(\mathbf{A}_m)v = q_{i+1}(\mathbf{A})v$$

e quindi la proprietà è vera per $i + 1$, con $i + 1 \leq m - 1$. Per il caso $i + 1 = m$, rimane solo da mostrare $\mathfrak{Q}_m q_m(\mathbf{A})v = q_m(\mathbf{A}_m)v$, che segue da $q_{m-1}(\mathbf{A})v = q_{m-1}(\mathbf{A}_m)v$ moltiplicando da entrambi i lati per $\mathfrak{Q}_m \mathbf{A}$. $\square$

Proposizione 2.2.3. Un sottospazio di Krylov $\mathcal{K}_m$ ha dimensione m se e solo se il grado di v rispetto ad $\mathbf{A}$ è m . Vale in generale che

$$\dim(\mathcal{K}_m) = \min\{m, \deg(v)\}.$$

Dimostrazione. I vettori $v, \mathbf{A}v, \mathbf{A}^2v, \dots, \mathbf{A}^{m-1}v$ formano una base di $\mathcal{K}_m$ se e solo se per ogni insieme di m scalari $\alpha_i = 0, \dots, m - 1$, dove almeno un α_i è non nullo, la combinazione lineare $\sum_{i=0}^{m-1} \alpha_i \mathbf{A}^i v$ è non nulla. Questo è equivalente alla condizione per cui il solo polinomio di grado $\leq m - 1$ tale che $p(\mathbf{A})v = 0$ è il polinomio nullo. La seconda parte della dimostrazione è una conseguenza della Proposizione 2.2.2 $\square$

In seguito, si enuncia una importante proprietà di ottimalità dei proiettori ortogonali.

Teorema 2.2.1. Sia $\mathfrak{P}$ il proiettore ortogonale su un sottospazio K . Allora, per ogni vettore $x \in \mathbb{R}^n$, è vero che:

$$\min_{y \in K} \|x - y\|^2 = \|x - \mathfrak{P}x\|^2. \quad (2.1)$$

Dimostrazione. Sia y un qualsiasi vettore di K e si considera il quadrato della sua distanza da x . Poiché $x - \mathfrak{P}x$ è ortogonale a K a cui appartiene $\mathfrak{P}x - y$, allora:

$$\|x - y\|^2 = \|x - \mathfrak{P}x + (\mathfrak{P}x - y)\|^2 = \|x - \mathfrak{P}x\|^2 + \|(\mathfrak{P}x - y)\|^2.$$

Pertanto, $\|x - y\|^2 \geq \|x - \mathfrak{P}x\|^2$ per ogni $y \in K$. Questo stabilisce il risultato notando che il minimo si raggiunge per $y = \mathfrak{P}x$. $\square$

Esprimendo le condizioni che definiscono $y^* \equiv \mathfrak{P}x$ per un proiettore ortogonale $\mathfrak{P}$ su un sottospazio K , è possibile riformulare il risultato precedente in una forma di condizioni necessarie e sufficienti che ci permettono di determinare la migliore approssimazione di un dato vettore x nel senso dei minimi quadrati.

Corollario 2.2.1. Sia dato un sottospazio K e un vettore $x \in \mathbb{R}^n$. Allora

$$\min_{y \in K} \|x - y\|^2 = \|x - y^*\|^2,$$

se e solo se le seguenti due condizioni sono soddisfatte:

$$\begin{cases} y^* \in K \\ x - y^* \perp K. \end{cases}$$

2.3 Metodo di Arnoldi

Il metodo di Arnoldi determina una base ortogonale del sottospazio di Krylov $\mathcal{K}_m$ in modo iterativo al crescere della dimensione dello spazio. Esistono quattro varianti principali di questo algoritmo, in questo contesto si mostreranno solo due di queste varianti, ovvero la versione GS (Gram-Schmidt) e la versione MGS (Modified Gram-Schmidt), la prima è la più intuitiva ma numericamente non stabile, la seconda è equivalente alla prima ma numericamente più stabile.

Algorithm 1 GS (Gram-Schmidt)

```
1: Si sceglie un vettore  $v_1$  di norma unitaria
2: for  $j = 1, 2, \dots, m$  do
3:   for  $i = 1, \dots, j$  do
4:     calcolo  $h_{i,j} = (Av_j, v_i)$ 
5:   end for
6:   calcolo  $w_j := Av_j - \sum_{i=1}^j h_{i,j} v_i$ 
7:    $h_{j+1,j} = \|w_j\|_2$ 
8:   if  $h_{j+1,j} = 0$  then
9:     stop
10:  else
11:     $v_{j+1} = w_j / h_{j+1,j}$ 
12:  end if
13: end for
```

Algorithm 2 MGS (Modified Gram-Schmidt)

```

1: Si sceglie un vettore  $v_1$  di norma unitaria
2: for  $j = 1, 2, \dots, m$  do
3:   calcolo  $w_j := Av_j$ 
4:   for  $i = 1, \dots, j$  do
5:     calcolo  $h_{i,j} = (w_j, v_i)$ 
6:     calcolo  $w_j = w_j - h_{i,j}v_i$ 
7:   end for
8:    $h_{j+1,j} = \|w_j\|_2$ 
9:   if  $h_{j+1,j} = 0$  then
10:    stop
11:  else
12:     $v_{j+1} = w_j/h_{j+1,j}$ 
13:  end if
14: end for

```

Osservazione 2.3.1. Il costo computazionale sia per il metodo di Gram-Schmidt (GS) che per il metodo di Gram-Schmidt modificato (MGS) è $2m^2n$, mentre la memoria richiesta è $(m+1)n$. Sebbene in aritmetica esatta entrambi gli algoritmi siano matematicamente equivalenti, in presenza di errori di arrotondamento, il metodo modificato risulta molto più affidabile.

La differenza principale risiede nel modo in cui viene eseguita l'ortogonalizzazione. Mentre l'Algoritmo 1 (GS) sottrae la proiezione su tutti i vettori ortogonali già calcolati in una volta sola, l'Algoritmo 2 (MGS) effettua l'ortogonalizzazione in modo incrementale per ciascun vettore, passo dopo passo. Questa strategia comporta una maggiore stabilità numerica. Infatti, nel metodo classico, gli errori di arrotondamento possono accumularsi, specialmente in spazi di dimensioni elevate, mentre il metodo modificato tende a minimizzare questi errori ripetendo l'ortogonalizzazione ad ogni passo.

Tuttavia, esistono casi in cui le cancellazioni durante i passaggi di ortogonalizzazione sono così gravi che anche l'uso del metodo di Gram-Schmidt modificato si rivela inadeguato. In tali circostanze, è possibile adottare ulteriori miglioramenti.

Un esempio di miglioramento consiste nella doppia ortogonalizzazione. Ogni volta che il vettore finale w_j , ottenuto al termine del ciclo principale nell'algoritmo, viene calcolato, si esegue un test per confrontare la sua norma con la norma iniziale del vettore w_j (ossia $\|Av_j\|_2$). Se la riduzione della norma scende al di sotto di una certa

soglia, indicando che potrebbero essersi verificate gravi cancellazioni, si procede a una seconda ortogonalizzazione.

Ad ogni passo, l'algoritmo moltiplica il vettore Arnoldi precedente v_j per $\mathbf{A}$ e successivamente ortonormalizza il vettore risultante w_j rispetto a tutti i precedenti v_i utilizzando una procedura standard di Gram-Schmidt. Si interromperà se il vettore w_j calcolato alla sesta linea risulta nullo. Questo caso sarà discusso nella Proposizione 2.4.3. Ora verranno dimostrate alcune semplici proprietà dell'algoritmo.

Proposizione 2.3.1. Se l'algoritmo 1 (o equivalente il 2) non si arresta dopo m passi allora i vettori $v_1, \dots, v_m$ formano una base ortonormale del sottospazio di Krylov

$$\mathcal{K}_m = \{v_1, \mathbf{A}v_1, \dots, \mathbf{A}^{m-1}v_1\}.$$

Dimostrazione. I vettori $v_j, j = 1, 2, \dots, m$, sono ortonormali per costruzione. Il fatto che generano $\mathcal{K}_m$ segue dal fatto che ogni vettore v_j è della forma $q_{j-1}(\mathbf{A})v_1$ dove q_{j-1} è un polinomio di grado $j-1$. Questo può essere mostrato per induzione su j nel modo seguente. L'affermazione precedente risulta vera per $j = 1$, siccome $v_1 = q_0(\mathbf{A})v_1$ con $q_0(t) \equiv 1$. Assumiamo che il risultato sia vero per tutti gli interi minori o uguali a j e consideriamo v_{j+1} . Abbiamo

$$h_{j+1}v_{j+1} = \mathbf{A}v_j - \sum_{i=1}^j h_{ij}v_i = \mathbf{A}q_{j-1}(\mathbf{A})v_1 - \sum_{i=1}^j h_{ij}q_{i-1}(\mathbf{A})v_1$$

Ciò mostra che v_{j+1} può essere espresso come $q_j(\mathbf{A})v_1$ dove q_j è di grado j e ciò completa la dimostrazione $\square$

Proposizione 2.3.2. Si consideri la matrice $\mathbf{V}_m \in \mathbb{R}^{n \times m}$ che ha per vettori colonna $v_1, \dots, v_m$ (base ortonormale di $\mathcal{K}_m$, calcolata ad esempio con l'algoritmo 1 o 2) e sia $\bar{\mathbf{H}}_m \in \mathbb{R}^{(m+1) \times m}$ la matrice (di Hessenberg) i cui elementi sono $h_{i,j} = (\mathbf{A}v_j, v_i)$ e sia $\mathbf{H}_m$ la matrice ottenuta da $\bar{\mathbf{H}}_m$ eliminando l'ultima riga. Allora valgono le seguenti relazioni

$$\mathbf{A}\mathbf{V}_m = \mathbf{V}_m\mathbf{H}_m + v_{m+1}h_{m+1,m}e_m^\top = \mathbf{V}_{m+1}, \bar{\mathbf{H}}_m \quad (2.2)$$

$$\mathbf{V}_m^\top \mathbf{A}\mathbf{V}_m = \mathbf{H}_m \quad (2.3)$$

Dimostrazione. La relazione (2.2) segue dalle uguaglianze nelle linee 6,7 e 11 dell'algoritmo 1. Infatti,

$$\mathbf{A}v_j = \sum_{i=1}^{j+1} h_{i,j} v_i \quad j = 1, \dots, m \quad (2.4)$$

La relazione (2.3) segue moltiplicando da sinistra tutti i membri della relazione (2.2) per $\mathbf{V}_m^\top$ e sfruttando l'ortonormalità di $\{v_1, \dots, v_m\}$. $\square$

Osservazione 2.3.2. L'azione di $\mathbf{A}$ su $\mathbf{V}_m$ dà $\mathbf{V}_m \mathbf{H}_m$ più una correzione di rango 1.

$$\mathbf{A} \mathbf{V}_m = \mathbf{V}_m \mathbf{H}_m + w_m \mathbf{e}_m^T$$

Figura 2.1. Immagine presa da [25]

Proposizione 2.3.3. L'algoritmo 1 o 2 si arresta al passo j -esimo (ovvero $h_{j+1,j}$) se il polinomio minimo di v_1 rispetto ad $\mathbf{A}$ ha grado j e in questo caso lo spazio $\mathcal{K}_j$ è invariante sotto l'azione di $\mathbf{A}$.

Dimostrazione. Se il grado del polinomio minimo è j , allora w_j deve essere uguale a 0. Infatti, altrimenti v_{j+1} può essere definito e di conseguenza $\mathcal{K}_{j+1}$ avrebbe dimensione $j+1$. Allora dalla proposizione 2.2.3 implicherebbe che $w_j = 0$. Allora il grado μ del polinomio minimo di v_1 è tale che $\mu \leq j$. Inoltre, è impossibile che $\mu < j$. Altrimenti, dalla prima parte della dimostrazione, il vettore w_μ sarebbe nullo e l'algoritmo

si fermerebbe ad un iterazione minore di μ . Il resto della dimostrazione segue dalla proposizione 2.2.1. $\square$

2.4 FOM

Il metodo di ortogonalizzazione completa, che sarà indicato con l'acronimo FOM (Full Orthogonalization Method), risolve il sistema lineare per proiezione scegliendo $L_m = K_m = \mathcal{K}_m$.

Dato x_0 una stima iniziale della soluzione allora si pone $r_0 = b - \mathbf{A}x_0$, $\mathcal{K}_m = \mathcal{K}_m(\mathbf{A}, r_0)$ e si cerca un'approssimazione della soluzione x_m nello spazio affine $x_0 + \mathcal{K}_m$ imponendo la condizione di Galerkin

$$b - \mathbf{A}x_m \perp K_m.$$

Se $v_1 = \frac{r_0}{\|r_0\|_2}$ nel metodo di Arnoldi, e si pone $\beta = \|r_0\|_2$, allora

$$\mathbf{V}_m^\top \mathbf{A} \mathbf{V}_m = \mathbf{H}_m$$

dalle relazioni della Proposizione 2.4.2 e

$$\mathbf{V}_m^\top r_0 = \mathbf{V}_m^\top (\beta v_1) = \beta e_1.$$

Quindi la soluzione approssimata nello sottospazio m -dimensionale sarà data da

$$x_m = x_0 + \mathbf{V}_m y_m,$$

dove

$$y_m = \mathbf{H}_m^{-1}(\beta e_1).$$

Per capire questa formula è sufficiente ricordare come è fatta una soluzione approssimata calcolata con un metodo per proiezione (si veda la sezione precedente), osservare che in questo caso $\mathbf{V}_m = \mathbf{W}_m$ e che $r_0 = \beta v_1$, inoltre si usa che $\mathbf{V}_m^\top v_1 = e_1$ per ortonormalità della base. Usando queste osservazioni, svolgendo il calcolo si trova esattamente la

formula appena scritta. Un'altra proprietà interessante di FOM è che si ha un controllo del residuo automatico come si può vedere dalla seguente proposizione

Proposizione 2.4.1.

$$r_m = b - \mathbf{A}x_m = -h_{m+1,m}e_m^\top y_m v_{m+1}$$

e, inoltre,

$$\|b - \mathbf{A}x_m\|_2 = h_{m+1,m}|e_m^\top y_m|.$$

Dimostrazione. Abbiamo le seguenti relazioni,

$$\begin{aligned} b - \mathbf{A}x_m &= b - \mathbf{A}(x_0 + \mathbf{V}_m y_m) \\ &= r_0 - \mathbf{A}\mathbf{V}_m y_m \\ &= \beta v_1 - \mathbf{V}_m \mathbf{H}_m y_m - h_{m+1,m}e_m^\top y_m v_{m+1}. \end{aligned}$$

Dalla definizione di y_m , si ha che $\mathbf{H}_m y_m = \beta e_1$. Inoltre, $\beta v_1 = \mathbf{V}_m e_1 \beta$ e quindi

$$\beta v_1 - \mathbf{V}_m \mathbf{H}_m y_m = 0 \text{ da cui segue il risultato.} \quad \square$$

Una stima approssimativa del costo di ciascun passo dell'algoritmo è determinata come segue. Se $\text{Nz}(\mathbf{A})$ è il numero di elementi non nulli di $\mathbf{A}$, allora m passi della procedura di Arnoldi richiederanno m prodotti matrice-vettore al costo di $2m \times \text{Nz}(\mathbf{A})$. Ciascuno dei passi del metodo di Gram-Schmidt costa approssimativamente $4 \times j \times n$ operazioni, il che porta il totale sui m passi a circa $2m^2 n$. Quindi, in media, un passo di FOM costa approssimativamente

$$2\text{Nz}(\mathbf{A}) + 2mn.$$

Per quanto riguarda lo spazio di memoria, sono necessari m vettori di lunghezza n per allocare spazio per la base $\mathbf{V}_m$. Ulteriori vettori devono essere utilizzati per mantenere la soluzione corrente e il termine noto, e un vettore di lavoro per il prodotto matrice-vettore. Inoltre, deve essere salvata la matrice di Hessenberg $\mathbf{H}_m$. Il totale di memoria è quindi approssimativamente

$$(m+3)n + \frac{m^2}{2}$$

Nella maggior parte delle situazioni m è piccolo rispetto ad n , quindi questa occupazione di memoria è dominata dal primo termine. Ci sono altre versioni efficienti di FOM, per tali versioni si rimanda alla referenza principale.

2.5 GMRES

2.5.1 Algoritmo di base

GMRES (Generalized Minimum Residual Method) è un metodo di proiezione dove si pone $K = \mathcal{K}_m$ e $L = \mathbf{A}\mathcal{K}_m$. Prima di ricavare l'algoritmo si andrà ad enunciare un risultato di ottimalità per il caso che si sta considerando.

Teorema 2.5.1. Sia $\mathbf{A}$ una matrice quadrata arbitraria e si assuma che $L = \mathbf{A}K$. Allora un vettore $\tilde{x}$ è il risultato di un metodo di proiezione su K ortogonalmente a L con vettore iniziale x_0 se e solo se esso minimizza la norma-2 del vettore residuo $b - \mathbf{A}x$ su $x \in x_0 + K$, ovvero, se e solo se

$$R(\tilde{x}) = \min_{x \in x_0 + K} R(x),$$

dove $R(x) \equiv \|b - \mathbf{A}x\|_2$.

Dimostrazione. Come visto nel Corollario 2.2.1, affinché $\tilde{x}$ sia il minimizzatore di $R(x)$, è necessario e sufficiente che $b - \mathbf{A}\tilde{x}$ sia ortogonale a tutti i vettori della forma $v = \mathbf{A}y$, dove y appartiene a K , cioè

$$\langle b - \mathbf{A}\tilde{x}, v \rangle = 0, \quad \forall v \in \mathbf{A}K,$$

che è precisamente la condizione di Petrov-Galerkin che definisce la soluzione approssimata $\tilde{x}$. □

Vale la pena notare che $\mathbf{A}$ non deve necessariamente essere non singolare nella proposizione sopra. Quando $\mathbf{A}$ è singolare, possono esistere infiniti vettori $\tilde{x}$ che soddisfano la condizione di ottimalità.

Un metodo per ricavare l'algoritmo consiste nello sfruttare la relazione (2.1) e la proprietà di ottimalità appena vista. Ogni vettore x in $x_0 + \mathcal{K}_m$ può essere scritto come

$$x = x_0 + \mathbf{V}_m y, \quad (2.5)$$

dove y è un vettore in $\mathbb{R}^m$. Definendo

$$J(y) = \|b - \mathbf{A}x\|_2 = \|b - \mathbf{A}(x_0 + \mathbf{V}_m y)\|_2, \quad (2.6)$$

la relazione (2.1) risulta in

$$b - \mathbf{A}x = b - \mathbf{A}(x_0 + \mathbf{V}_m y) = r_0 - \mathbf{A}\mathbf{V}_m y = \beta v_1 - \mathbf{V}_{m+1} \bar{\mathbf{H}}_m y = \mathbf{V}_{m+1} (\beta e_1 - \bar{\mathbf{H}}_m y). \quad (2.7)$$

Poiché i vettori colonna di $\mathbf{V}_{m+1}$ sono ortonormali, allora

$$J(y) \equiv \|b - \mathbf{A}(x_0 + \mathbf{V}_m y)\|_2 = \|\beta e_1 - \bar{\mathbf{H}}_m y\|_2. \quad (2.8)$$

L'approssimazione GMRES è l'unico vettore di $x_0 + \mathcal{K}_m$ che minimizza (2.5). Da (2.4) e (2.7), questa approssimazione può essere ottenuta come $x_m = x_0 + \mathbf{V}_m y_m$, dove y_m minimizza la funzione $J(y) = \|\beta e_1 - \bar{\mathbf{H}}_m y\|_2$, ovvero,

$$x_m = x_0 + \mathbf{V}_m y_m, \quad \text{dove} \quad y_m = \arg \min_{y \in \mathbb{R}^m} \|\beta e_1 - \bar{\mathbf{H}}_m y\|_2. \quad (2.9)$$

Il minimizzatore y_m è poco costoso da calcolare, poiché richiede la soluzione di un problema di minimi quadrati di dimensione $(m+1) \times m$, dove m è tipicamente piccolo. Questo dà luogo al seguente algoritmo.

Algorithm 3 GMRES

```

1: Calcola  $r_0 = b - Ax_0$ ,  $\beta := \|r_0\|_2$ , e  $v_1 := r_0/\beta$ 
2: for  $j = 1, 2, \dots, m$  do
3:   Calcola  $w_j := Av_j$ 
4:   for  $i = 1, \dots, j$  do
5:      $h_{ij} := (w_j, v_i)$ 
6:      $w_j := w_j - h_{ij}v_i$ 
7:   end for
8:    $h_{j+1,j} = \|w_j\|_2$ . Se  $h_{j+1,j} = 0$  imposta  $m := j$  e vai a 11
9:    $v_{j+1} = w_j/h_{j+1,j}$ 
10: end for
11: Si definisce la matrice di Hessenberg  $(m+1) \times m$   $H_m = \{h_{ij}\}_{1 \leq i \leq m+1, 1 \leq j \leq m}$ 
12: Si calcola  $y_m$  che minimizza  $\|\beta e_1 - H_m y\|_2$  e  $x_m = x_0 + V_m y_m$ 

```

2.5.2 Aspetti implementativi

Una difficoltà evidente dell'Algoritmo 3 è che non fornisce la soluzione approssimata x_m esplicitamente ad ogni passo. Di conseguenza, non è facile determinare quando fermarsi. Un rimedio consiste nel calcolare la soluzione approssimata x_m a intervalli regolari e verificare la convergenza, ad esempio, tramite un test sul residuo. Tuttavia, esiste una soluzione più elegante che è collegata al modo in cui viene risolto il problema dei minimi quadrati (2.8).

Una tecnica comune per risolvere il problema dei minimi quadrati $\min \|\beta e_1 - \bar{H}_m y\|_2$, consiste nel trasformare la matrice di Hessenberg in forma triangolare superiore utilizzando rotazioni di Givens. Si definiscono le matrici di rotazione

$$\Omega_i = \begin{pmatrix} 1 & & & & & \\ & \ddots & & & & \\ & & c_i & s_i & & \\ & & -s_i & c_i & & \\ & & & & \ddots & \\ & & & & & 1 \end{pmatrix}$$

con $c_i^2 + s_i^2 = 1$. Se vengono eseguiti m passi dell'iterazione GMRES, queste matrici

avranno dimensione $(m+1) \times (m+1)$.

Si moltiplica la matrice di Hessenberg $\bar{\mathbf{H}}_m$ e il corrispondente termine noto $\bar{g}_0 \equiv \beta e_1$ per una sequenza di tali matrici da sinistra. I coefficienti s_i, c_i sono scelti per eliminare $h_{i+1,i}$ ogni volta. Ad esempio, se $m = 5$ si avrebbe

$$\bar{\mathbf{H}}_5 = \begin{pmatrix} h_{11} & h_{12} & h_{13} & h_{14} & h_{15} \\ h_{21} & h_{22} & h_{23} & h_{24} & h_{25} \\ & h_{32} & h_{33} & h_{34} & h_{35} \\ & & h_{43} & h_{44} & h_{45} \\ & & & h_{54} & h_{55} \\ & & & & h_{65} \end{pmatrix}, \quad \bar{g}_0 = \begin{pmatrix} \beta \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{pmatrix}.$$

Moltiplichiamo quindi $\bar{\mathbf{H}}_5$ da sinistra con

$$\mathbf{\Omega}_1 = \begin{pmatrix} c_1 & s_1 & & & \\ -s_1 & c_1 & & & \\ & & 1 & & \\ & & & \ddots & \\ & & & & 1 \end{pmatrix}$$

per ottenere la matrice e il termine noto

$$\bar{\mathbf{H}}_5^{(1)} = \begin{pmatrix} h_{11}^{(1)} & h_{12}^{(1)} & h_{13}^{(1)} & h_{14}^{(1)} & h_{15}^{(1)} \\ 0 & h_{22}^{(1)} & h_{23}^{(1)} & h_{24}^{(1)} & h_{25}^{(1)} \\ & h_{32} & h_{33} & h_{34} & h_{35} \\ & & h_{43} & h_{44} & h_{45} \\ & & & h_{54} & h_{55} \\ & & & & h_{65} \end{pmatrix}, \quad \bar{g}_1 = \begin{pmatrix} c_1 \beta \\ -s_1 \beta \\ 0 \\ 0 \\ 0 \\ 0 \end{pmatrix}.$$

Si può ora moltiplicare nuovamente la matrice e il termine noto per una matrice di

rotazione Ω_2 per eliminare h_{32} . Questo si ottiene prendendo

$$s_2 = \frac{h_{32}}{\sqrt{(h_{22}^{(1)})^2 + h_{32}^2}}, \quad c_2 = \frac{h_{22}^{(1)}}{\sqrt{(h_{22}^{(1)})^2 + h_{32}^2}}.$$

Questo processo di eliminazione continua fino a quando viene applicata la m-esima rotazione, che trasforma il problema in uno che coinvolge la matrice e il termine noto

$$\bar{\mathbf{H}}_5^{(5)} = \begin{pmatrix} h_{11}^{(5)} & h_{12}^{(5)} & h_{13}^{(5)} & h_{14}^{(5)} & h_{15}^{(5)} \\ 0 & h_{22}^{(5)} & h_{23}^{(5)} & h_{24}^{(5)} & h_{25}^{(5)} \\ 0 & 0 & h_{33}^{(5)} & h_{34}^{(5)} & h_{35}^{(5)} \\ 0 & 0 & 0 & h_{44}^{(5)} & h_{45}^{(5)} \\ 0 & 0 & 0 & 0 & h_{55}^{(5)} \end{pmatrix}, \quad \bar{\mathbf{g}}_5 = \begin{pmatrix} \gamma_1 \\ \gamma_2 \\ \gamma_3 \\ \gamma_4 \\ \gamma_5 \\ \gamma_6 \end{pmatrix}. \quad (2.10)$$

Generalmente, gli scalari c_i e s_i della i-esima rotazione Ω_i sono definiti come

$$s_i = \frac{h_{i+1,i}}{\sqrt{(h_{ii}^{(i-1)})^2 + h_{i+1,i}^2}}, \quad c_i = \frac{h_{ii}^{(i-1)}}{\sqrt{(h_{ii}^{(i-1)})^2 + h_{i+1,i}^2}}.$$

Definiamo $\mathbf{Q}_m$ come il prodotto delle matrici Ω_i ,

$$\mathbf{Q}_m = \Omega_m \Omega_{m-1} \cdots \Omega_1$$

e

$$\bar{\mathbf{R}}_m = \bar{\mathbf{H}}_m^{(m)} = \mathbf{Q}_m \bar{\mathbf{H}}_m, \quad \bar{\mathbf{g}}_m = \mathbf{Q}_m(\beta e_1) = (\gamma_1, \dots, \gamma_{m+1})^\top. \quad (2.11)$$

Il minimo del problema dei minimi quadrati $\min \|\beta e_1 - \bar{\mathbf{H}}_m y\|_2$ si ottiene risolvendo semplicemente il sistema triangolare risultante dall'eliminazione dell'ultima riga della matrice $\bar{\mathbf{R}}_m$ e del termine noto $\bar{\mathbf{g}}_m$ in (6.36). Inoltre, è chiaro che per la soluzione y^* , il "residuo" $\|\beta e_1 - \bar{\mathbf{H}}_m y^*\|$ non è altro che l'ultimo elemento del termine noto, cioè il termine γ_6 in (2.9).

Proposizione 2.5.1. Sia $m \leq n$ e Ω_i , $i = 1, \dots, m$ le matrici di rotazione utilizzate per trasformare $\bar{\mathbf{H}}_m$ in forma triangolare superiore. Si denotano con $\mathbf{R}_m$,

$\bar{g}_m = (\gamma_1, \dots, \gamma_{m+1})^\top$ la matrice risultante e il termine noto, come definiti in (2.10), e con $\mathbf{R}_m$, g_m la matrice triangolare superiore $m \times m$ e il vettore m -dimensionale ottenuti da $\bar{\mathbf{R}}_m$, $\bar{g}_m$ eliminando rispettivamente l'ultima riga e l'ultima componente. Allora,

1. Il rango di $\mathbf{A}\mathbf{V}_m$ è uguale al rango di $\mathbf{R}_m$. In particolare, se $r_{mm} = 0$, allora $\mathbf{A}$ deve essere singolare.
2. Il vettore y_m che minimizza $\|\beta e_1 - \bar{\mathbf{H}}_m y\|_2$ è dato da

$$y_m = \mathbf{R}_m^{-1} g_m.$$

3. Il vettore residuo al passo m soddisfa

$$b - \mathbf{A}x_m = \mathbf{V}_{m+1}(\beta e_1 - \bar{\mathbf{H}}_m y_m) = \mathbf{V}_{m+1} \mathbf{Q}_m^\top (\gamma_{m+1} e_{m+1}) \quad (2.12)$$

e, come risultato,

$$\|b - \mathbf{A}x_m\|_2 = |\gamma_{m+1}|. \quad (2.13)$$

Dimostrazione. Per dimostrare la prima parte (1), si utilizza (2.1) per ottenere la relazione

$$\mathbf{A}\mathbf{V}_m = \mathbf{V}_{m+1} \bar{\mathbf{H}}_m = \mathbf{V}_{m+1} \mathbf{Q}_m^\top \mathbf{Q}_m \bar{\mathbf{H}}_m = \mathbf{V}_{m+1} \mathbf{Q}_m^\top \bar{\mathbf{R}}_m.$$

Poiché $\mathbf{V}_{m+1} \mathbf{Q}_m^\top$ è unitaria, il rango di $\mathbf{A}\mathbf{V}_m$ è uguale a quello di $\bar{\mathbf{R}}_m$, che è uguale al rango di $\mathbf{R}_m$ poiché queste due matrici differiscono solo per una riga di zeri (l'ultima riga di $\bar{\mathbf{R}}_m$). Se $r_{mm} = 0$, allora $\mathbf{R}_m$ ha rango $\leq m - 1$ e, di conseguenza, $\mathbf{A}\mathbf{V}_m$ ha rango $\leq m - 1$. Poiché $\mathbf{V}_m$ è di rango completo, ciò significa che $\mathbf{A}$ deve essere singolare.

La seconda parte (2) è stata essenzialmente dimostrata prima della proposizione. Per qualsiasi vettore y ,

$$\|\beta e_1 - \bar{\mathbf{H}}_m y\|_2 = \|\mathbf{Q}_m(\beta e_1 - \bar{\mathbf{H}}_m y)\|_2 = \|\bar{g}_m - \bar{\mathbf{R}}_m y\|_2 = |\gamma_{m+1}|^2 + \|g_m - \mathbf{R}_m y\|_2.$$

Il minimo del termine di sinistra è raggiunto quando il secondo termine a destra nell'ultima uguaglianza è zero. Poiché $\mathbf{R}_m$ è non singolare, ciò si ottiene quando

$$y_m = \mathbf{R}_m^{-1} g_m.$$

Per dimostrare la terza parte (3), iniziamo con le definizioni utilizzate per GMRES e la relazione (2.6). Per qualsiasi $x = x_0 + \mathbf{V}_m y$,

$$b - \mathbf{A}x = \mathbf{V}_{m+1}(\beta e_1 - \bar{\mathbf{H}}_m y) = \mathbf{V}_{m+1} \mathbf{Q}_m^\top \mathbf{Q}_m (\beta e_1 - \bar{\mathbf{H}}_m y) = \mathbf{V}_{m+1} \mathbf{Q}_m^\top (\bar{g}_m - \bar{\mathbf{R}}_m y).$$

Come visto nella dimostrazione della seconda parte sopra, la norma-2 di $\bar{g}_m - \bar{\mathbf{R}}_m y$ è minimizzata quando y annulla tutte le componenti del termine noto $\bar{g}_m$ eccetto l'ultima, che è uguale a γ_{m+1} . Di conseguenza,

$$b - \mathbf{A}x_m = \mathbf{V}_{m+1} \mathbf{Q}_m^\top (\gamma_{m+1} e_{m+1})$$

che è (2.11). Il risultato (2.12) segue dall'ortogonalità delle colonne di $\mathbf{V}_{m+1} \mathbf{Q}_m^\top$. $\square$

Osservazione 2.5.1. Finora è stato descritto solo un processo per calcolare la soluzione ai minimi quadrati y_m dell'equazione (2.8). Tale approccio con le rotazioni piane può anche essere utilizzato per risolvere il sistema lineare nel metodo FOM. L'unica differenza è che l'ultima rotazione $\mathbf{\Omega}_m$ deve essere omessa. In particolare, è possibile scrivere un unico programma per implementare entrambi gli algoritmi utilizzando un controllo per selezionare le opzioni FOM o GMRES.

È possibile implementare il processo sopra descritto in modo progressivo, cioè a ogni passo dell'algoritmo GMRES. Questo approccio consentirà di ottenere la norma del residuo a ogni passo, con praticamente nessuna operazione aritmetica aggiuntiva. Per illustrare questo, iniziamo dalla (2.9), ovvero assumiamo che le prime m rotazioni siano già state applicate. Ora la norma del residuo è disponibile per x_5 e il criterio di arresto può essere applicato. Supponiamo che il test indichi che devono essere fatti ulteriori passi. Deve essere eseguito un altro passo dell'algoritmo di Arnoldi per ottenere $\mathbf{A}v_6$ e la sesta colonna di $\bar{\mathbf{H}}_6$. Questa colonna viene aggiunta a $\bar{\mathbf{R}}_5$, che è stata ampliata da una riga di zeri per corrispondere alla dimensione. Quindi le rotazioni precedenti $\mathbf{\Omega}_1, \mathbf{\Omega}_2, \dots, \mathbf{\Omega}_5$ vengono applicate a quest'ultima colonna. Dopo questo si ottengono la seguente matrice e il termine noto (ora i pedici h_{ij} non hanno più apici):

$$\overline{\mathbf{H}}_6 = \begin{pmatrix} h_{11} & h_{12} & h_{13} & h_{14} & h_{15} & h_{16} \\ & h_{22} & h_{23} & h_{24} & h_{25} & h_{26} \\ & & h_{33} & h_{34} & h_{35} & h_{36} \\ & & & h_{44} & h_{45} & h_{46} \\ & & & & h_{55} & h_{56} \\ & & & & 0 & h_{66} \\ & & & & 0 & h_{76} \end{pmatrix}, \quad \overline{\mathbf{g}}_6 = \begin{pmatrix} \gamma_1 \\ \gamma_2 \\ \gamma_3 \\ \vdots \\ \gamma_6 \\ 0 \end{pmatrix}.$$

L'algoritmo continua ora nello stesso modo di prima. È necessario premoltiplicare la matrice per una matrice di rotazione $\mathbf{\Omega}_6$ (ora di dimensione 7×7) con

$$s_6 = \frac{h_{76}}{\sqrt{(h_{66}^{(5)})^2 + h_{76}^2}}, \quad c_6 = \frac{h_{66}^{(5)}}{\sqrt{(h_{66}^{(5)})^2 + h_{76}^2}}$$

per ottenere la matrice e il termine noto:

$$\overline{\mathbf{R}}_6 = \begin{pmatrix} r_{11} & r_{12} & r_{13} & r_{14} & r_{15} & r_{16} \\ & r_{22} & r_{23} & r_{24} & r_{25} & r_{26} \\ & & r_{33} & r_{34} & r_{35} & r_{36} \\ & & & r_{44} & r_{45} & r_{46} \\ & & & & r_{55} & r_{56} \\ & & & & & r_{66} \\ & & & & & 0 \end{pmatrix}, \quad \overline{\mathbf{g}}_6 = \begin{pmatrix} \gamma_1 \\ \gamma_2 \\ \gamma_3 \\ \vdots \\ c_6 \gamma_6 \\ -s_6 \gamma_6 \end{pmatrix}. \quad (2.14)$$

Se la norma del residuo, data da $|\gamma_{m+1}|$, è abbastanza piccola, il processo deve essere interrotto. Le ultime righe di $\overline{\mathbf{R}}_m$ e $\overline{\mathbf{g}}_m$ vengono eliminate e il sistema triangolare superiore risultante viene risolto per ottenere y_m . Successivamente, viene calcolata la soluzione approssimata $x_m = x_0 + \mathbf{V}_m y_m$.

Notare che da (2.13) si ottiene la seguente utile relazione per γ_{j+1} :

$$\gamma_{j+1} = -s_j \gamma_j. \quad (2.15)$$

In particolare, se $s_j = 0$, allora la norma del residuo deve essere pari a zero, il che

significa che la soluzione è esatta al passo j .

2.5.3 Condizioni di arresto

Se l'Algoritmo 3 viene esaminato attentamente, si osserva che le uniche possibilità che l'algoritmo termini si verificano nel ciclo di Arnoldi, quando $w_j = 0$, cioè quando $h_{j+1,j} = 0$ a un dato passo j . In questa situazione, l'algoritmo si arresta perché il prossimo vettore di Arnoldi non può essere generato. Tuttavia, in questa situazione, il vettore residuo è zero, cioè l'algoritmo fornirà la soluzione esatta a questo passo. In effetti, anche il contrario è vero: se l'algoritmo si arresta al passo j con $b - \mathbf{A}x_j = 0$, allora $h_{j+1,j} = 0$.

Proposizione 2.5.2. Sia $\mathbf{A}$ una matrice non singolare. Allora, l'algoritmo GMRES si arresta al passo j , cioè $h_{j+1,j} = 0$, se e solo se la soluzione approssimata x_j è esatta.

Dimostrazione. Per dimostrare la condizione necessaria, si osservi che se $h_{j+1,j} = 0$, allora $s_j = 0$. Infatti, poiché $\mathbf{A}$ è non singolare, $r_{jj} = h_{j,j-1}$ è diverso da zero per la prima parte della Proposizione 2.6.1, e da come è costruito s_j implica che $s_j = 0$. Poi, le relazioni (2.12) e (2.14) implicano che $r_j = 0$.

Per dimostrare la condizione sufficiente, usiamo ancora una volta (2.14). Poiché la soluzione è esatta al passo j e non al passo $j - 1$, allora $s_j = 0$. Dalla costruzione degli scalari s_i , questo implica che $h_{j+1,j} = 0$. $\square$

2.6 Convergenza di GMRES: cenni

Si può studiare il comportamento di convergenza di GMRES sfruttando proprietà di ottimalità. D'altra parte, per algoritmi non ottimali come FOM sarà più difficile fare un'analisi, per questo motivo non verrà fatta un'analisi più dettagliata per tale metodo. Iniziamo enunciando un risultato di convergenza globale. Si ricorda che una matrice $\mathbf{A} \in \mathbb{R}^{n \times n}$ è chiamata definita positiva se la sua parte simmetrica $\frac{\mathbf{A} + \mathbf{A}^\top}{2}$ è simmetrica definita positiva. Questo è equivalente alla proprietà che $\langle \mathbf{A}x, x \rangle > 0$ per tutti i vettori reali non nulli $x \in \mathbb{R}^n$.

Definizione 2.6.1. (GMRES(m))

GMRES(m) è una variante dell'algoritmo GMRES che utilizza una tecnica chiamata "restarting" o "ripartenza". Tale tecnica consiste nel riavviare l'algoritmo GMRES dopo ogni m iterazioni ripartendo dal residuo corrente. In altre parole, invece di far crescere il sottospazio di Krylov indefinitamente, si limita la dimensione del sottospazio a m , e si riparte con il vettore residuo ottenuto al termine di quelle m iterazioni.

Teorema 2.6.1. Se $\mathbf{A}$ è una matrice definita positiva, allora GMRES(m) converge per ogni $m \geq 1$.

Dimostrazione. Questo è vero perché il sottospazio $\mathcal{K}_m$ contiene il residuo iniziale ad ogni ripartenza. Poiché l'algoritmo minimizza la norma del residuo nel sottospazio $\mathcal{K}_m$, ad ogni iterazione esterna, la norma del residuo verrà ridotta tanto quanto il risultato di un passo di un metodo detto del Residuo Minimo. Pertanto, grazie a disuguaglianze sui residui si deduce che il metodo converge. Per maggiori dettagli si rimanda a [25]. $\square$

Ora si desidera stabilire un risultato che fornisce un limite superiore sul tasso di convergenza delle iterate di GMRES. Si considera inizialmente il seguente lemma.

Lemma 2.6.1. Sia x_m la soluzione approssimata ottenuta dal m -esimo passo dell'algoritmo GMRES, e sia $r_m = b - \mathbf{A}x_m$. Allora, x_m è della forma

$$x_m = x_0 + q_m(\mathbf{A})r_0$$

e

$$\|r_m\|_2 = \|(I - \mathbf{A}q_m(\mathbf{A}))r_0\|_2 = \min_{q \in \mathbb{P}_{m-1}} \|(I - \mathbf{A}q(\mathbf{A}))r_0\|_2.$$

dove $\mathbb{P}_{m-1}$ è l'insieme dei polinomi di grado al più $m - 1$ ad una variabile.

Dimostrazione. Questo è vero perché x_m minimizza la norma-2 del residuo nello spazio affine $x_0 + \mathcal{K}_m$, come risultato del Teorema 2.5.1, e del fatto che $\mathcal{K}_m$ è l'insieme di tutti i vettori della forma $x_0 + q(\mathbf{A})r_0$, dove q è un polinomio di grado $\leq m - 1$. $\square$

Proposizione 2.6.1. Supponiamo che $\mathbf{A}$ sia una matrice diagonalizzabile e sia $\mathbf{A} = \mathbf{X}\mathbf{\Lambda}\mathbf{X}^{-1}$ dove $\mathbf{\Lambda} = \text{diag}\{\lambda_1, \lambda_2, \dots, \lambda_n\}$ è la matrice diagonale degli autovalori. Definiamo

$$\epsilon(m) = \min_{p \in \mathbb{P}_m, p(0)=1} \max_{i=1, \dots, n} |p(\lambda_i)|.$$

Allora, la norma del residuo ottenuta al m -esimo passo di GMRES soddisfa la seguente disuguaglianza

$$\|r_m\|_2 \leq \kappa_2(\mathbf{X}) \epsilon(m) \|r_0\|_2. \quad (2.16)$$

Dimostrazione. Sia p un qualsiasi polinomio di grado $\leq m$ che soddisfa il vincolo $p(0) = 1$, e sia x il vettore in $\mathcal{K}_m$ ad esso associato tramite $b - \mathbf{A}x = p(\mathbf{A})r_0$. Allora,

$$\|b - \mathbf{A}x\|_2 = \|\mathbf{X}p(\mathbf{\Lambda})\mathbf{X}^{-1}r_0\|_2 \leq \|\mathbf{X}\|_2 \|\mathbf{X}^{-1}\|_2 \|r_0\|_2 \|p(\mathbf{\Lambda})\|_2.$$

Poiché $\mathbf{\Lambda}$ è diagonale, si osserva che

$$\|p(\mathbf{\Lambda})\|_2 = \max_{i=1, \dots, n} |p(\lambda_i)|.$$

Poiché x_m minimizza la norma del residuo su $x_0 + \mathcal{K}_m$, allora per qualsiasi polinomio p ,

$$\|b - \mathbf{A}x_m\|_2 \leq \|b - \mathbf{A}x\|_2 \leq \|\mathbf{X}\|_2 \|\mathbf{X}^{-1}\|_2 \|r_0\|_2 \max_{i=1, \dots, n} |p(\lambda_i)|.$$

Ora può essere utilizzato il polinomio p che minimizza il termine a destra nella disuguaglianza sopra. Questo ci porta al risultato desiderato,

$$\|b - \mathbf{A}x_m\|_2 \leq \|b - \mathbf{A}x\|_2 \leq \|\mathbf{X}\|_2 \|\mathbf{X}^{-1}\|_2 \|r_0\|_2 \epsilon(m).$$

□

Osservazione 2.6.1. Supponendo, nelle ipotesi della Proposizione 2.6.1, che gli autovalori di $\mathbf{A}$ siano contenuti in un ellisse nel piano complesso è possibile ricavare una stima migliore della norma del residuo concentrandosi su $\epsilon(m)$ sfruttando i polinomi di Chebyshev. Per maggiori dettagli si rimanda a [25].

Capitolo 3

ϵ -sottospazio di embedding

In questo capitolo verranno discussi i sottospazi di embedding, importanti strumenti utili per poter lavorare con spazi di dimensioni più piccole. La principale referenza in questo capitolo è [32].

3.1 Sottospazio di embedding

Si inizia con la nozione di base di un ℓ_2 -sottospazio di embedding per lo spazio delle colonne di una matrice $n \times d$ $\mathbf{A}$. Nel corso del capitolo, per numeri reali non negativi a e b , si usa la notazione $a = (1 \pm \epsilon)b$ se $a \in [(1 - \epsilon)b, (1 + \epsilon)b]$.

Definizione 3.1.1. (ϵ -sottospazio di embedding) Sia $\mathcal{V}$ un sottospazio vettoriale di $\mathbb{R}^n$. Dato $\epsilon \in [0,1)$, sia $\mathbf{S} \in \mathbb{R}^{s \times n}$ tale che per per ogni $v \in \mathcal{V}$,

$$\|\mathbf{S}\mathbf{A}v\|_2 = (1 \pm \epsilon) \|\mathbf{A}v\|_2. \quad (3.1)$$

dove $\|\cdot\|$ denota la norma euclidea. In tal caso $\mathbf{S}$ viene detto ϵ -sottospazio di embedding

Osservazione 3.1.1. La definizione di ϵ -sottospazio di embedding $\mathbf{S}$ induce un prodotto interno

$$\langle u, v \rangle_{\mathbf{S}} := \langle \mathbf{S}u, \mathbf{S}v \rangle.$$

Osservazione 3.1.2. Si osserva che se $\mathbf{S}$ è un $(1 \pm \epsilon)$ ℓ_2 -sottospazio di embedding per $\mathbf{A}$, allora è anche un $(1 \pm \epsilon)$ ℓ_2 -sottospazio di embedding per $\mathbf{U}$, dove $\mathbf{U}$ è una matrice avente come colonne una base ortonormale per lo spazio delle colonne di $\mathbf{A}$. Questo perché gli insiemi $\{\mathbf{A}x \mid x \in \mathbb{R}^d\}$ e $\{\mathbf{U}y \mid y \in \mathbb{R}^t\}$ sono uguali, dove t è il rango di $\mathbf{A}$. Pertanto, è possibile senza perdita di generalità assumere che $\mathbf{A}$ abbia colonne ortonormali. Con questa interpretazione, il requisito della definizione precedente diventa

$$\|\mathbf{S}\mathbf{U}y\|_2 = (1 \pm \epsilon)\|\mathbf{U}y\|_2 = (1 \pm \epsilon)\|y\|_2,$$

dove l'uguaglianza finale vale poiché $\mathbf{U}$ ha colonne ortonormali. Se questo requisito è soddisfatto per i vettori unitari y , allora è soddisfatto per tutti i vettori y per omotetia (poiché $\mathbf{S}$ è una mappa lineare), quindi il requisito della definizione precedente può essere ulteriormente semplificato a

$$\|\mathbf{I}_d - \mathbf{U}^\top \mathbf{S}^\top \mathbf{S} \mathbf{U}\|_2 \leq \epsilon,$$

cioè, la norma operatore $\sup_{\|y\|_2=1} \|\mathbf{I}_d - \mathbf{U}^\top \mathbf{S}^\top \mathbf{S} \mathbf{U}\|_2$, deve essere al massimo ϵ

Ci sono vari obiettivi per costruire dei efficienti sottospazi di embedding. Due degli obiettivi principali sono trovare una matrice $\mathbf{S}$ con un numero ridotto di righe ed essere in grado di calcolare $\mathbf{S} \cdot \mathbf{A}$ rapidamente, poiché questo è una richiesta ricorrente nelle applicazioni.

Ci sono diversi modi per costruire degli ℓ_2 -sottospazi di embedding che raggiungono vari compromessi. Una forma particolarmente utile di ℓ_2 -sottospazio di embedding è un oblivious ℓ_2 -sottospazio di embedding.

Definizione 3.1.2. (Oblivious sottospazio di embedding) Supponiamo che Π sia una distribuzione su matrici $r \times n$ $\mathbf{S}$, dove r è una funzione di n, d, ϵ e δ . Supponiamo che con probabilità almeno $1 - \delta$, per qualsiasi matrice fissata $n \times d$ $\mathbf{A}$, una matrice $\mathbf{S}$ estratta dalla distribuzione Π abbia la proprietà che $\mathbf{S}$ sia un ℓ_2 -sottospazio di embedding $(1 \pm \epsilon)$ per $\mathbf{A}$. Allora si chiama Π un ℓ_2 -oblivious (ϵ, δ) sottospazio di embedding.

3.2 Trasformate di Johnson-Lindenstrauss

Ritornando alla Definizione 3.1.2, uno degli utilizzi più efficaci di questa nella comunità dell'algebra lineare numerica, per quanto si sappia, è stato fatto da Sárlos, che ha proposto l'uso delle trasformate di Johnson-Lindenstrauss rapide per fornire sottospazio di embedding. Si seguirà l'esposizione di [26] per tali argomenti.

Definizione 3.2.1. Una matrice random $\mathbf{S} \in \mathbb{R}^{k \times n}$ forma una trasformata di Johnson-Lindenstrauss con parametri ϵ, δ, f , o JLT(ϵ, δ, f) in breve, se con probabilità almeno $1 - \delta$, per qualsiasi sottoinsieme V di f elementi in $\mathbb{R}^n$, per tutti $v, v' \in V$ si ha che

$$|\langle \mathbf{S}v, \mathbf{S}v' \rangle - \langle v, v' \rangle| \leq \epsilon \|v\|_2 \|v'\|_2.$$

Osservazione 3.2.1. Si osserva che se $v = v'$ si ottiene che $\|\mathbf{S}v\|_2 = (1 \pm \epsilon)\|v\|_2$. Se si scalassero tutti $v, v' \in V$ in modo che siano vettori unitari, si potrebbe alternativamete richiedere $\|\mathbf{S}v\|_2 = (1 \pm \epsilon)\|v\|_2$ e $\|\mathbf{S}(v + v')\|_2 = (1 \pm \epsilon)\|v + v'\|_2$ per tutti $v, v' \in V$. Cioè, il requisito della definizione potrebbe essere basato sulle norme piuttosto che sui prodotti interni. Per vedere che ciò implica l'affermazione sopra, si ha

$$\begin{aligned} \langle \mathbf{S}v, \mathbf{S}v' \rangle &= \frac{\|\mathbf{S}(v + v')\|_2^2 - \|\mathbf{S}v\|_2^2 - \|\mathbf{S}v'\|_2^2}{2} \\ &= \frac{(1 \pm \epsilon)\|v + v'\|_2^2 - (1 \pm \epsilon)\|v\|_2^2 - (1 \pm \epsilon)\|v'\|_2^2}{2} \\ &= \langle v, v' \rangle \pm O(\epsilon), \end{aligned}$$

che implica che tutti i prodotti interni sono preservati fino a ϵ riscalando ϵ con una costante.

Ci sono molte costruzioni di trasformate di Johnson-Lindenstrauss, una delle più semplici è data dal seguente teorema.

Teorema 3.2.1 (Johnson-Lindenstrauss Transform (JLT), vedi [13]). Siano $0 < \epsilon < 1$ e $0 < \delta < 1$, e sia $\mathbf{S} = \sqrt{\frac{1}{k}} \mathbf{R} \in \mathbb{R}^{k \times n}$, dove gli elementi $R_{i,j}$ della matrice $\mathbf{R}$ sono variabili casuali indipendenti che seguono una distribuzione normale standard $\mathcal{N}(0,1)$. Allora, se $k = \Omega\left(\frac{\log(f/\delta)}{\epsilon^2}\right)$, la matrice $\mathbf{S}$ soddisfa le proprietà della trasdormata di Johnson-Lindenstrauss (JLT) con parametri (ϵ, δ, f) .

La dimostrazione del Teorema 3.2.1 segue dal Lemma 3.2.1.

Mostriamo come il Teorema 3.2.1 può essere utilizzato per fornire un embedding di sottospazio ℓ_2 . Per fare ciò, abbiamo bisogno del concetto di ϵ -rete.

Definizione 3.2.2. Sia $\mathcal{S} = \{y \in \mathbb{R}^n \mid y = \mathbf{A}x \text{ per qualche } x \in \mathbb{R}^d \text{ e } \|y\|_2 = 1\}$. Sia un sottoinsieme finito di $\mathcal{S}$, denotato $\mathcal{N}$, tale che se

$$\langle \mathbf{S}w, \mathbf{S}w' \rangle = \langle w, w' \rangle \pm \epsilon \text{ per tutti } w, w' \in \mathcal{N}, \quad (3.2)$$

allora $\|\mathbf{S}y\|_2 = (1 \pm \epsilon)\|y\|_2$ per ogni $y \in \mathcal{S}$. Allora diremo che $\mathcal{N}$ è una ϵ -rete.

Osservazione 3.2.2. Con un argomento di [2],[11],[17], è sufficiente scegliere $\mathcal{N}$ in modo che per tutti $y \in \mathcal{S}$, esista un vettore $w \in \mathcal{N}$ per il quale $\|y - w\|_2 \leq 1/2$. Ci riferiremo a $\mathcal{N}$ come a una $(1/2)$ -rete per $\mathcal{S}$.

Per vedere che $\mathcal{N}$ è sufficiente, se y è un vettore unitario, allora si può scrivere

$$y = y_0 + y_1 + y_2 + \cdots, \quad (3.3)$$

dove $\|y_i\| \leq \frac{1}{2^i}$ e y_i è un multiplo scalare di un vettore in $\mathcal{N}$. Questo è vero perché possiamo scrivere $y = y_0 + (y - y_0)$ dove $y_0 \in \mathcal{N}$ e $\|y - y_0\| \leq 1/2$ per la definizione di $\mathcal{N}$. Poi, $y - y_0 = y_1 + ((y - y_0) - y_1)$ dove $y_1 \in \mathcal{N}$ e

$$\|y - y_0 - y_1\|_2 \leq \frac{\|y - y_0\|_2}{2} \leq \frac{1}{4}.$$

Lo sviluppo in (3.3) segue quindi per induzione. Ma allora,

$$\begin{aligned} \|\mathbf{S}y\|_2 &= \|\mathbf{S}(y_0 + y_1 + y_2 + \cdots)\|_2 \\ &= \sum_{0 \leq i < j < \infty} \|\mathbf{S}y_i\|_2^2 + 2\langle \mathbf{S}y_i, \mathbf{S}y_j \rangle \\ &= \left(\sum_{0 \leq i < j < \infty} \|y_i\|_2^2 + 2\langle y_i, y_j \rangle \right) \pm 2\epsilon \left(\sum_{0 \leq i \leq j < \infty} \|y_i\|_2 \|y_j\|_2 \right) \\ &= 1 \pm O(\epsilon), \end{aligned}$$

dove la prima uguaglianza segue da (3.3), la seconda uguaglianza segue sviluppando il quadrato, la terza segue da (3.2) e la quarta è ciò che si vuole ottenere (riscaldando eventualmente ϵ per una costante).

Si vuole mostrare ora l'esistenza di una piccola $(1/2)$ -rete $\mathcal{N}$ tramite un argomento standard.

Lemma 3.2.1. Per ogni $0 < \gamma < 1$, esiste una γ -rete $\mathcal{N}$ di $\mathcal{S}$ per la quale $|\mathcal{N}| \leq (1 + 4/\gamma)^d$.

Dimostrazione. Per $t = \text{rank}(A) \leq d$, possiamo esprimere equivalentemente $\mathcal{S}$ come

$$\mathcal{S} = \{y \in \mathbb{R}^n \mid y = \mathbf{U}x \text{ per qualche } x \in \mathbb{R}^t \text{ e } \|y\|_2 = 1\},$$

dove $\mathbf{U}$ ha colonne ortonormali che generano lo stesso spazio generato dalle colonne di $\mathbf{A}$. Scegliamo una $\gamma/2$ -rete $\mathcal{N}'$ della sfera unitaria $\mathcal{S}^{t-1}$, dove la $\gamma/2$ -rete misura $(1 + 4/\gamma)^\top$. L'intuizione per questa scelta è che $\mathbf{U}$ fornisce un'isometria quando opera su $\mathcal{S}^{t-1}$, e quindi una rete per $\mathcal{S}^{t-1}$ ci darà una rete per l'immagine di $\mathcal{S}^{t-1}$ sotto $\mathcal{U}$.

Questo può essere fatto scegliendo un insieme massimo $\mathcal{N}'$ di punti su $\mathcal{S}^{t-1}$ in modo che nessuna coppia di punti sia a una distanza inferiore a $\gamma/2$. Ne consegue che le sfere di raggio $\gamma/4$ centrate su questi punti sono disgiunte, ma d'altra parte sono tutte contenute nella sfera di raggio $1 + \gamma/4$ centrata nell'origine. Il volume di quest'ultima sfera è un fattore $(1 + \gamma/4)^\top / (\gamma/4)^\top$ maggiore delle sfere più piccole, il che implica che $|\mathcal{N}'| \leq (1 + 4/\gamma)^\top$. Vedi, ad esempio, [18] per maggiori dettagli.

Definiamo $\mathcal{N} = \{y \in \mathbb{R}^n \mid y = \mathbf{U}x \text{ per qualche } x \in \mathcal{N}'\}$. Poiché le colonne di $\mathbf{U}$ sono ortonormali, se ci fosse un punto $\mathbf{U}x \in \mathcal{S}$ per il quale non esiste un punto $y \in \mathcal{N}$ con $\|y - \mathbf{U}x\|_2 \leq \gamma$, allora x sarebbe un punto in $\mathcal{S}^{t-1}$ per il quale non c'è un punto $z \in \mathcal{N}'$ con $\|x - z\|_2 \leq \gamma$. Ciò è una contraddizione. $\square$

Ne consegue che imponendo $V = \mathcal{N}$ e $f = 9^d$ nel Teorema 3.2.1, possiamo quindi applicare il Lemma e (3.2) per ottenere il seguente Teorema. Si osserva che la misura della rete non dipende da ϵ , poiché servirà solo una $1/2$ -rete per l'argomento, anche se il teorema vale per un ϵ generico.

Teorema 3.2.2. Sia $0 < \epsilon$, $\delta < 1$ e $\mathbf{S} = \sqrt{\frac{1}{k}} \mathbf{R} \in \mathbb{R}^{k \times n}$ dove le entrate $R_{i,j}$ di $\mathbf{R}$ sono variabili casuali normali standard indipendenti. Allora, se $k = \Theta((d + \log(1/\delta))\epsilon^{-2})$, per qualsiasi matrice $n \times d$ fissata $\mathbf{A}$, con probabilità $1 - \delta$, $\mathbf{S}$ è un $(1 \pm \epsilon)$ ℓ_2 sottospazio di embedding per $\mathbf{A}$, cioè, per tutti gli $x \in \mathbb{R}^d$, $\|\mathbf{S}\mathbf{A}x\|_2 = (1 \pm \epsilon)\|\mathbf{A}x\|_2$. Qui $C > 0$ è una costante reale.

Osservazione 3.2.3. Per n sufficientemente grande e se $\mathbf{S}$ è una matrice i.i.d Gaussian, è sufficiente che $r = \Omega(d/\epsilon^2)$ per far sì che $\mathbf{S}$ sia un ϵ -sottospazio di embedding per lo spazio generato dalle colonne di una matrice $\mathbf{A} \in \mathbb{R}^{n \times d}$ ([32])

3.3 Trasformate di Johnson-Lindenstrauss rapide: Cenni

Grazie al Teorema 3.2.1 sono stati fatti altri esperimenti su diverse matrici $\mathbf{R}$ sparse in modo tale da rendere il prodotto $\mathbf{S}x$ con x vettore in $\mathbb{R}^n$ più veloce. L'idea principale era quella di studiare il numero di nonzeri minimo in ogni colonna della matrice $\mathbf{S}$ affinché si avessero buoni risultati in termini probabilistici. Una linea di lavoro diversa fu intrapresa da Ailon e Chazelle [1]. Invece di provare a ottenere una matrice $\mathbf{S}$ sparsa provarono a ricercare una matrice generica $\mathbf{S}$ da poter applicare ad un vettore generico in modo rapido. L'intuizione di base è che per un vettore $x \in \mathbb{R}^n$ con norma ℓ_2 distribuita uniformemente, selezionare alcune coordinate casualmente e riscalarle fornisce una buona stima della norma ℓ_2 di x . Tuttavia, se x è sparso, questo metodo fallisce poiché la maggior parte dei campioni sarà zero. Per il principio di incertezza, se x è sparso, allora $\mathbf{F}x$ (trasformata di Fourier) non può essere troppo sparso. Questo vale anche per la trasformata di Hadamard $\mathbf{H}x$ e per qualsiasi sistema ortonormale limitato.

Purtroppo, $\mathbf{H}x$ può ancora essere troppo sparso, quindi si ri-randomizza $\mathbf{H}x$ applicando una rotazione casuale. Si calcola $\mathbf{H}\mathbf{D}x$ dove $\mathbf{D}$ è una matrice diagonale con entrate $D_{i,i}$ i.i.d., in cui $D_{i,i} = 1$ con probabilità $1/2$ e $D_{i,i} = -1$ con probabilità $1/2$. Se $\mathbf{P}$ è una matrice $k \times n$ che seleziona le coordinate, allora $\mathbf{P}\mathbf{H}\mathbf{D}x$ fornisce la trasformata di Johnson-Lindenstrauss desiderata.

I vantaggi della forma $\mathbf{P}\mathbf{H}\mathbf{D}x$ sono i seguenti:

- $\mathbf{D}x$ può essere calcolato in $O(n)$ tempo.

- $\mathbf{H}x$ può essere calcolato in $O(n \log n)$ tempo.
- $\mathbf{P}$ può essere applicata in $O(k)$ tempo.

Pertanto, $\mathbf{PHD}$ può essere applicata a un vettore in $O(n \log n)$ tempo e a una matrice $n \times d$ in $O(nd \log n)$ tempo, rendendola significativamente più veloce rispetto ai metodi precedenti. Questa trasformata, chiamata Trasformata Rapida di Johnson-Lindenstrauss, è stata utilizzata per ottenere miglioramenti di velocità in regressione e approssimazione di matrici di basso rango. Il seguente teorema mostrerà una versione specifica chiamata Trasformata di Hadamard randomizzata sottocampionata (SRHT) utilizzata da Woodruff in [32]

Teorema 3.3.1. (Trasformata di Hadamard randomizzata sottocampionata). Sia $\mathbf{S} = \sqrt{\frac{1}{k}} \mathbf{P} \mathbf{H}_n \mathbf{D}$, dove $\mathbf{D}$ è una matrice diagonale $n \times n$ con entrate diagonali i.i.d. $D_{i,i}$ in cui $D_{i,i} = 1$ con probabilità $1/2$, e $D_{i,i} = -1$ con probabilità $1/2$. $\mathbf{H}_n$ si riferisce alla matrice di Hadamard di dimensione n , che assumiamo sia una potenza di 2. Qui, l'elemento (i, j) -esimo di $\mathbf{H}_n$ è dato da

$$\frac{(-1)^{\langle i, j \rangle}}{\sqrt{n}},$$

dove $\langle i, j \rangle = \sum_{z=1}^{\log n} i_z \cdot j_z$, e dove $(i_{\log n}, \dots, i_1)$ e $(j_{\log n}, \dots, j_1)$ sono le rappresentazioni binarie di i e j rispettivamente. La matrice $r \times n$ $\mathbf{P}$ seleziona r coordinate random di un vettore n -dimensionale in modo uniforme, dove

$$r = \Omega(\epsilon^{-2}(\log d)(\sqrt{d} + \log n)).$$

Allora, con probabilità almeno 0.99, per qualsiasi matrice $n \times d$ fissata $\mathbf{U}$ con colonne ortonormali,

$$\|\mathbf{I}_d - \mathbf{U}^\top \mathbf{S}^\top \mathbf{S} \mathbf{U}\|_2 \leq \epsilon.$$

Inoltre, per qualsiasi vettore $x \in \mathbb{R}^n$, $\mathbf{S}x$ può essere calcolato in tempo $O(n \log r)$.

Dimostrazione. Per la dimostrazione di tale teorema si veda [1],[26],[8],[9],[31]

□

Osservazione 3.3.1. Un altro esempio di Trasformata di Johnson Lindenstrauss rapida utilizzata in [20] è la seguente

$$\mathbf{S} = \sqrt{\frac{k}{n}} \mathbf{P} \mathbf{C} \mathbf{D}$$

dove $\mathbf{P}$ e $\mathbf{D}$ sono le stesse matrici descritte nel Teorema 3.3.1 e $\mathbf{C} \in \mathbb{R}^{n \times n}$ è la trasformata discreta dei coseni.

Capitolo 4

Metodo Sketched ed Arnoldi troncato su spazi di Krylov per equazioni matriciali

In questo capitolo si andrà a introdurre il materiale necessario alla costruzione dell'algoritmo per la risoluzione dell'equazione:

$$\mathbf{A}\mathbf{X} + \mathbf{X}\mathbf{A}^\top + \mathbf{M}\mathbf{X}\mathbf{M}^\top = \mathbf{C}\mathbf{C}^\top \quad (4.1)$$

dove $\mathbf{A} \in \mathbb{R}^{n \times n}$, $\mathbf{M} \in \mathbb{R}^{n \times n}$ sono matrici simmetriche definite positive sparse, $\mathbf{C} \in \mathbb{R}^n$ e $\mathbf{X} \in \mathbb{R}^{n \times n}$ è soluzione incognita dell'equazione. Indicheremo anche con $\mathcal{L}(\mathbf{X}) = \mathbf{A}\mathbf{X} + \mathbf{X}\mathbf{A}^\top + \mathbf{M}\mathbf{X}\mathbf{M}^\top$ il membro di sinistra di (4.1), dove $\mathcal{L} : \mathbb{R}^{n \times n} \rightarrow \mathbb{R}^{n \times n}$.

4.1 Approccio iniziale

Classicamente, il problema è stato trattato ricorrendo alla formulazione di Kronecker, già descritta nel primo capitolo, dando origine a un sistema lineare standard (vettoriale). Più precisamente, sia $\mathcal{A} = \mathcal{A}_0 + \mathcal{M}$ dove

$$\mathcal{A}_0 = \mathbf{A} \otimes \mathbf{I} + \mathbf{I} \otimes \mathbf{A}, \quad \mathcal{M} = \mathbf{M} \otimes \mathbf{M}.$$

Quindi, (4.1) è equivalente a

$$\mathcal{A}x = c, \quad c = \text{Vec}(CC^\top), \quad (4.2)$$

Osservazione 4.1.1. $\mathcal{A}$ è simmetrica definita positiva per la Proposizione 1.1.4.

Un approccio più efficiente consiste nell'utilizzare il metodo di Galerkin per poter determinare una approssimazione della soluzione in maniera meno costosa e più rapida cercando appunto di sfruttare le proprietà delle matrici. L'idea è di cercare una soluzione approssimata nella forma $\mathbf{X}_k = \mathbf{V}_k \mathbf{Y}_k \mathbf{V}_k^\top$ dove le colonne ortonormali di $\mathbf{V}_k$ formano uno spazio di approssimazione specificamente selezionato di dimensione bassa, e $\mathbf{Y}_k$ è una matrice di piccole dimensioni, determinata imponendo alcune condizioni sulle approssimazioni. La procedura è iterativa, e lo spazio viene ampliato se l'approssimazione non è sufficientemente buona; il parametro k rappresenta il numero di iterazioni. Definendo $\mathbf{R}_k = CC^\top - (\mathbf{A}\mathbf{X}_k + \mathbf{X}_k\mathbf{A} + \mathbf{M}\mathbf{X}_k\mathbf{M})$, in questo contesto questa condizione può essere formalizzata come

$$\mathbf{V}_k^\top \mathbf{R}_k \mathbf{V}_k = 0.$$

Sostituendo la forma $\mathbf{X}_k = \mathbf{V}_k \mathbf{Y}_k \mathbf{V}_k^\top$ per qualche $\mathbf{Y}$, otteniamo

$$(\mathbf{V}_k^\top \mathbf{A} \mathbf{V}_k) \mathbf{Y} + \mathbf{Y} (\mathbf{V}_k^\top \mathbf{A} \mathbf{V}_k) + (\mathbf{V}_k^\top \mathbf{M} \mathbf{V}_k) \mathbf{Y} (\mathbf{V}_k^\top \mathbf{M} \mathbf{V}_k) = \mathbf{V}_k^\top CC^\top \mathbf{V}_k. \quad (4.3)$$

Pertanto, $\mathbf{Y}_k$ può essere ottenuto come soluzione dell'equazione matriciale ridotta (4.3) che ha la stessa struttura del problema originale, ma dimensioni molto più piccole.

Osservazione 4.1.2. $\mathbf{V}_k^\top \mathbf{A} \mathbf{V}_k$ e $\mathbf{V}_k^\top \mathbf{M} \mathbf{V}_k$ sono simmetriche definite positive.

È stato dimostrato in [22] che se si considera un problema con operatore associato della forma $\mathcal{L} : \mathbf{X} \mapsto \sum_{j=1}^{\ell} \mathbf{A}_j \mathbf{X} \mathbf{B}_j$ simmetrico e definito positivo, allora la proiezione di Galerkin è ottimale, nel senso che minimizza l'errore nella norma corrispondente. Più precisamente, vale il seguente risultato.

Proposizione 4.1.1. Per $\mathbf{X} \in \mathbb{R}^{n_1 \times n_2}$ sia $\mathcal{L} : \mathbf{X} \mapsto \sum_{j=1}^{\ell} \mathbf{A}_j \mathbf{X} \mathbf{B}_j$ un operatore simmetrico e definito positivo, con $\mathbf{A}_j \in \mathbb{R}^{n_1 \times n_1}$, $\mathbf{B}_j \in \mathbb{R}^{n_2 \times n_2}$. Sia $\mathbf{X}^*$ la soluzione esatta

del problema $\mathcal{L}(\mathbf{X}) = \mathbf{C}$, e siano $\text{range}(\mathbf{V}_k)$, $\text{range}(\mathbf{W}_k)$ gli spazi di approssimazione costruiti, in modo che $\mathbf{X}_k = \mathbf{V}_k \mathbf{Y}_k \mathbf{W}_k^\top$ sia la soluzione approssimata di Galerkin. Allora

$$\|\mathbf{X}^* - \mathbf{X}_k\|_{\mathcal{L}} = \min_{\substack{\mathbf{Z} = \mathbf{V}_k \mathbf{Y} \mathbf{W}_k^\top \\ \mathbf{Y} \in \mathbb{R}^{k \times k}}} \|\mathbf{X}^* - \mathbf{Z}\|_{\mathcal{L}},$$

dove la norma è definita come

$$\|\mathbf{X}\|_{\mathcal{L}}^2 = \text{trace} \left(\sum_{j=1}^{\ell} \mathbf{X}^\top \mathbf{A}_j \mathbf{X} \mathbf{B}_j \right).$$

Osservazione 4.1.3. Per risolvere (4.3), grazie all'Osservazione 4.1.2, è possibile utilizzare il metodo dei gradienti coniugati orientato alle matrici. Il metodo del gradiente coniugato (CG) orientato alle matrici trasforma semplicemente tutti i calcoli vettoriali associati al caso (4.2) in operazioni matriciali, utilizzando gli operatori Vec e di Kronecker. Quindi, per esempio, per l'aggiornamento classico della soluzione approssimata (vedi Appendice A per l'algoritmo CG vettoriale), vale che

$$x_{k+1} = x_k + \alpha_k p_k \iff \mathbf{X}_{(k+1)} = \mathbf{X}_{(k)} + \alpha_k \mathbf{P}_{(k)}$$

dove $x_k = \text{Vec}(\mathbf{X}_{(k)})$, $p_k = \text{Vec}(\mathbf{P}_{(k)})$ e

$$\alpha_k = \frac{r_k^\top p_k}{p_k^\top \mathcal{A} p_k} = \frac{\text{trace}((\mathbf{R}_{(k)})^\top \mathbf{P}_{(k)})}{\text{trace}((\mathbf{P}_{(k)})^\top \mathcal{L}(\mathbf{P}_{(k)}))}$$

dove $r_k = c - \mathcal{A}x_k$ è il vettore residuo associato a x_k . Per una descrizione completa dell'algoritmo e per ulteriori analisi si rimanda a [29].

4.2 Spazi di proiezione e relazione di Arnoldi troncata

Il passo fondamentale per l'efficacia di questa procedura di Galerkin è la scelta dello spazio di approssimazione. Gli spazi che considereremo d'ora in avanti sono spazi di

Krylov $\mathcal{K}_d(\mathbf{A}, \mathbf{M}^\top, C) := \text{range}(\mathbf{V}_k)$ generati nella seguente maniera:

$$V_0 = C, \quad \mathbf{V}_k = [\mathbf{V}_{k-1}, \mathbf{A}v_k, \mathbf{M}v_k], \quad k = 1, 2, \dots,$$

dove v_k è il k -esimo vettore di $\mathbf{V}_{k-1}$, quindi:

$$\left\{ \begin{array}{l} V_0 = C =: \underline{v}_1 \\ \mathbf{V}_1 = [v_1, \mathbf{A}v_1, \mathbf{M}v_1] =: [v_1, \underline{v}_2, v_3] \\ \mathbf{V}_2 = [\mathbf{V}_1, \mathbf{A}v_2, \mathbf{M}v_2] =: [v_1, v_2, \underline{v}_3, v_4] \\ \dots \end{array} \right. \quad (4.4)$$

Assumendo che la matrice calcolata abbia rango massimo, il sottospazio generato ha dimensione $\dim(\text{range}(\mathbf{V}_k)) = 2k + 1$, $k = 0, 1, \dots$

Senza ortogonalizzazione, la matrice generata da questa procedura cresce come

$$\mathbf{V}_\infty = [C, \mathbf{A}C, \mathbf{M}C, \mathbf{A}^2C, \mathbf{M}\mathbf{A}C, \mathbf{A}\mathbf{M}C, \mathbf{M}^2C, \mathbf{A}^3C, \mathbf{M}\mathbf{A}^2C, \mathbf{A}\mathbf{M}\mathbf{A}C, \dots]$$

La seguente proposizione fornisce una rappresentazione esplicita dei vettori in $\text{range}(\mathbf{V}_k)$.

Proposizione 4.2.1. Sia $p \in \text{range}(\mathbf{V}_k)$. Allora esistono γ_i , $\alpha_{i,l}$ e $\beta_{i,l}$ tali che

$$p = \sum_{i=0}^k \gamma_i \sum_{l=0}^i (\alpha_{i,l} \mathbf{A} + \beta_{i,l} \mathbf{M}) C.$$

In modo più compatto, definendo $\phi_i(\xi, \eta) = \prod_{l=0}^i (\alpha_{i,l} \xi + \beta_{i,l} \eta)$ come il polinomio bivariato di grado non superiore a i , vale che

$$p = \sum_{i=0}^k \gamma_i \phi_i(\mathbf{A}, \mathbf{M}) c_1.$$

Dimostrazione. Si osserva che per ogni $i \leq k$, il vettore $0 \neq w = \phi_i(\mathbf{A}, \mathbf{M})C$ è una combinazione lineare di elementi in $\text{range}(\mathbf{V}_k)$ di grado esatto i in almeno $\mathbf{A}$ o $\mathbf{M}$. $\square$

Il passo successivo è quello di trovare una base ortonormale per lo spazio $\mathcal{K}_d(\mathbf{A}, \mathbf{M}^\top, C)$ e si procede nel seguente modo:

- Si supponga che l'algoritmo sia alla d -esima iterazione :
 1. Siano i vettori $[w_{2d+1}, w_{2d+2}] = [\mathbf{A}v_d, \mathbf{B}v_d]$.
 Per $j = 1, 2, \dots, 2d$:
 - Si calcola $H_{j,k} = v_j^{2d+1}$ e $G_{j,k} = v_j^{2d+2}$
 - $w_{2d+1} = w_{2d+1} - H_{j,k}v_j$ e $w_{2d+2} = w_{2d+2} - G_{j,k}v_j$
 2. Infine si ortonormalizzano i vettori w_{2d+1} e w_{2d+2} ottenendo due vettori ortonormali v_{2d+1} e v_{2d+2} .
 3. Se $\mathbf{V}_{d+1} = [\mathbf{V}_d, v_{2d+1}, v_{2d+2}]$ ha rango massimo allora l'insieme dei vettori colonna è una base ortonormale per lo spazio $\mathcal{K}_d(\mathbf{A}, \mathbf{M}^\top, C)$, altrimenti si estrae una base ortonormale e si considera questa come base per lo spazio di Krylov.

Osservazione 4.2.1. Fissato $k \geq 1$, per ridurre il costo di tale procedimento si può considerare il metodo di Arnoldi troncato che consiste nella ortogonalizzazione dei vettori w_{2d+1} e w_{2d+2} rispetto agli ultimi k vettori della base $\mathbf{V}_d$. Tuttavia per metodi tradizionali citati in precedenza ciò porta ad un ritardo della convergenza del metodo a causa dell'ortogonalità locale della base. Fenomeni di questo tipo sono ben documentati per esempio in [30].

4.3 Sketching incontra Krylov

Il metodo descritto in precedenza, come altri metodi tradizionali basati sulle formulazioni del prodotto di Kronecker, presentano degli ostacoli. Quando la dimensione dei dati con cui si lavora inizia ad essere troppo grande i metodi iniziano ad essere molto costosi in termini di tempo e memoria. Ciò è dovuto ad alcuni fattori principali:

- Memoria utilizzata per allocare in macchina l'intera base di Krylov
- Ortogonalizzazione dei nuovi vettori della base rispetto all'intera base
- Calcoli troppo costosi dovuti alle grandi dimensioni delle matrici.

Per mitigare questi problemi entra in gioco il potenziale dello sketching, già mostrato per esempio in [20].

L'idea appunto è di combinare i sottospazi di Krylov con gli sottospazi oblivious di embedding al fine di aumentare l'efficienza computazionale nel passo di ortogonalizzazione e potenzialmente ridurre i requisiti di memoria. Tale argomento è già stato studiato nel contesto di sistemi lineari e problemi agli autovalori (vedi, per esempio, [4],[19]) così come nell'approssimazione di funzioni di matrici (vedi, per esempio, [6],[20],[5]). Inoltre, come mostrato in [20, 4, 6], è possibile usare un metodo di Arnoldi troncato insieme ad un subspace di embedding $\mathbf{S}$ che permette di "ortogonalizzare approssimativamente" la base di Krylov ad un costo molto inferiore.

Osservazione 4.3.1. Sia $\mathbf{V}_d \in \mathbb{R}^{n \times (2d+1)}$ matrice di rango massimo avente come colonne una base per lo spazio di Krylov $\mathcal{K}_d(\mathbf{A}, \mathbf{M}^\top, C)$ e $\mathbf{S}$ subspace di embedding relativo allo spazio generato dalle colonne di $\mathbf{V}$. Si considera $\mathbf{SV} = \mathbf{QR}$ la fattorizzazione QR ridotta di $\mathbf{SV}$ allora sia $\hat{\mathbf{V}} = \mathbf{VR}^{-1}$. Grazie alle proprietà dello sketching tale matrice è una matrice ben condizionata (vedi, per esempio [4]) con condizionamento

$$\kappa_2(\hat{\mathbf{V}}) \leq \sqrt{\frac{1-\epsilon}{1+\epsilon}}.$$

Inoltre, se $\mathbf{V}_d$ è una matrice con colonne ortonormali allora $\hat{\mathbf{V}}_d$ è una matrice con colonne ortonormali rispetto al prodotto interno $\langle \cdot, \cdot \rangle_{\mathbf{S}}$ definito nell'Osservazione 3.1.1.

Ad ogni iterazione lo scopo è trovare una soluzione della forma $\mathbf{X}_d = \hat{\mathbf{V}}_d \mathbf{Y}_d \hat{\mathbf{V}}_d^\top$ dove $\hat{\mathbf{V}}_d \in \mathbb{R}^{n \times 2d+1}$ è definita come nella precedente osservazione, $\mathbf{Y}_d \in \mathbb{R}^{2d+1 \times 2d+1}$ è la soluzione ridotta calcolata imponendo la condizione di Galerkin sul residuo in forma sketching, ovvero

$$\hat{\mathbf{V}}_d^\top \mathbf{S}_V^\top \mathbf{S}_V \mathbf{R}_d^{SK} \mathbf{S}_V^\top \mathbf{S}_V \hat{\mathbf{V}}_d = 0, \quad (4.5)$$

dove

$$\mathbf{R}_d^{SK} = \mathbf{A}\mathbf{X}_d + \mathbf{X}_d\mathbf{A}^\top + \mathbf{M}\mathbf{X}_d\mathbf{M}^\top - \mathbf{C}\mathbf{C}^\top. \quad (4.6)$$

Esplicitando i conti nel membro di sinistra in (4.5) e sfruttando il fatto che $\mathbf{S}_V \hat{\mathbf{V}}_d = \mathbf{Q}_d$

matrice ortogonale per costruzione, allora si ottiene la seguente equazione:

$$\mathbf{A}_d \mathbf{Y}_d + \mathbf{Y}_d \mathbf{A}_d^\top + \mathbf{M}_d \mathbf{Y}_d \mathbf{M}_d^\top - C_d C_d^\top = 0, \quad (4.7)$$

con $\mathbf{A}_d = \mathbf{Q}_d^\top \mathbf{S}_V \mathbf{A} \widehat{\mathbf{V}}_d$, $\mathbf{M}_d = \mathbf{Q}_d^\top \mathbf{S}_V \mathbf{M} \widehat{\mathbf{V}}_d$ e $C_d = \mathbf{Q}_d^\top \mathbf{S}_V C$.

Osservazione 4.3.2. Le matrici $\mathbf{A}_d, \mathbf{M}_d \in \mathbb{R}^{d \times d}$ in generale non sono simmetriche e inoltre non sono sparse. Quindi per risolvere l'equazione ridotta non è possibile usare un metodo del tipo descritto nella sezione 4.1.

4.4 Calcolo del residuo

Per quanto riguarda il calcolo del residuo si può riscrivere (3.2) nella seguente forma:

$$\mathbf{R}_d^{SK} = \mathbf{B} \Upsilon \mathbf{B}^\top, \quad (4.8)$$

dove $\mathbf{B} = [\mathbf{A} \widehat{\mathbf{V}}_d, \widehat{\mathbf{V}}_d, \mathbf{M} \widehat{\mathbf{V}}_d, C]$ e $\Upsilon = \begin{bmatrix} \mathbf{O}_{d,d} & \mathbf{Y}_d & \mathbf{O}_{d,d} & \mathbf{O}_{d,1} \\ \mathbf{Y}_d & \mathbf{O}_{d,d} & \mathbf{O}_{d,d} & \mathbf{O}_{d,1} \\ \mathbf{O}_{d,d} & \mathbf{O}_{d,d} & \mathbf{Y}_d & \mathbf{O}_{d,1} \\ \mathbf{O}_{1,d} & \mathbf{O}_{1,d} & \mathbf{O}_{1,d} & -1 \end{bmatrix}$

con $\mathbf{O}_{i,j} \in \mathbb{R}^{i \times j}$ matrice di zeri.

Il calcolo della norma di Frobenius del residuo risulta essere troppo costoso all'aumentare delle iterazioni in quanto le matrici in questione hanno dimensioni enormi.

A tal proposito grazie ad alcuni risultati si riesce a darne una stima calcolando $\|\mathbf{S}_V \mathbf{R}_d^{SK} \mathbf{S}_V^\top\|_F$ risultando come operazione meno costosa rispetto alla precedente. Infatti grazie ad operazioni di aggiornamento è possibile eludere l'alto costo di applicazione dello sketching all'intera matrice $\mathbf{B}$ ed inoltre le dimensioni diminuiscono quindi è possibile effettuare il prodotto tra matrici senza cercare strategie alternative.

Proposizione 4.4.1. ([4]) Sia $\mathbf{S} \in \mathbb{R}^{s \times n}$ un ϵ -sottospazio di embedding di $\mathcal{V}$ con $\dim(\mathcal{V}) = 2d + 1$ e supponiamo $\mathcal{V}$ una matrice avente come colonne una base ortonormale di $\mathcal{V}$. Allora $\mathbf{S}\mathbf{V}$ è un ϵ -sottospazio di embedding per $\mathbb{R}^{2d+1}$

Dimostrazione. Sia $z \in \mathbb{R}^{2d+1}$. Allora $\mathbf{V}z \in \mathcal{V}$, quindi dalla definizione di ϵ -sottospazio di embedding si ha:

$$(1 - \epsilon) \|\mathbf{V}z\|^2 \leq \|\mathbf{S}\mathbf{V}z\|^2 \leq (1 + \epsilon) \|\mathbf{V}z\|^2,$$

Il risultato segue notando che $\|\mathbf{V}z\| = \|z\|$ per il fatto che $\mathbf{V}$ ha colonne ortonormali. □

Lemma 4.4.1. ([4]) Siano i numeri naturali r_2 , n_1 e n_2 , e supponiamo che una matrice random $\mathbf{S} \in \mathbb{R}^{r_2 \times n_2}$ sia un oblivious (ϵ, δ) -embedding l_2 di $\mathbb{R}^{n_2}$, il che significa che con probabilità almeno $1 - \delta$, $\mathbf{S}$ preserva la norma l_2 con accuratezza ϵ , cioè,

$$| \|\mathbf{S}x\|_2 - \|x\|_2 | \leq \epsilon \|x\|_2 \quad \text{per ogni } x \in \mathbb{R}^{n_2}.$$

Allora il prodotto di Kronecker $\mathbf{I}_{n_1} \otimes \mathbf{S}$ è un oblivious (ϵ, δ) -embedding l_2 di $\mathbb{R}^{n_1 n_2}$. Similmente, se $\mathbf{S} \in \mathbb{R}^{r_1 \times n_1}$ è un oblivious (ϵ, δ) -embedding l_2 di $\mathbb{R}^{n_1}$, allora $\mathbf{S} \otimes \mathbf{I}_{n_2}$ è un oblivious (ϵ, δ) -embedding l_2 di $\mathbb{R}^{n_1 n_2}$.

Dimostrazione. Le dimostrazioni per le due affermazioni sono piuttosto simili, quindi dimostriamo solo la prima affermazione. Qualsiasi $x \in \mathbb{R}^{n_1 n_2}$ può essere scritto nella seguente forma:

$$x = \begin{bmatrix} x_1 \\ \vdots \\ x_{n_1} \end{bmatrix}, \quad \text{dove } x_i \in \mathbb{R}^{n_2}, \quad i = 1, 2, \dots, n_1.$$

Allora

$$(\mathbf{I}_{n_1} \otimes \mathbf{S})x = \begin{bmatrix} \mathbf{S}x_1 \\ \vdots \\ \mathbf{S}x_{n_1} \end{bmatrix}.$$

Quindi

$$\|(\mathbf{I}_{n_1} \otimes \mathbf{S})x\|_2^2 = \sum_{i=1}^{n_1} \|\mathbf{S}x_i\|_2^2, \quad \|x\|_2^2 = \sum_{i=1}^{n_1} \|x_i\|_2^2.$$

Poiché $\mathbf{S}$ è un oblivious (ε, δ) -embedding l_2 di $\mathbb{R}^{n_2}$, allora con probabilità almeno $1 - \delta$, per ogni $x_i \in \mathbb{R}^{n_2}$, si ha

$$\left| \|\mathbf{S}x_i\|_2 - \|x_i\|_2 \right| \leq \varepsilon \|x_i\|_2 \quad \text{per ogni } i = 1, 2, \dots, n_1.$$

Utilizzando questo limite, con probabilità almeno $1 - \delta$, si ha per ogni $x \in \mathbb{R}^{n_1 n_2}$

$$\left| \|(\mathbf{I}_{n_1} \otimes \mathbf{S})x\|_2 - \|x\|_2 \right| \leq \sum_{i=1}^{n_1} \left| \|\mathbf{S}x_i\|_2 - \|x_i\|_2 \right| \leq \varepsilon \sum_{i=1}^{n_1} \|x_i\|_2 = \varepsilon \|x\|_2,$$

così che $\mathbf{I}_{n_1} \otimes \mathbf{S}$ è un (ε, δ) -embedding l_2 di $\mathbb{R}^{n_1 n_2}$, come affermato. $\square$

Corollario 4.4.1. ([4]) Siano due matrici random $\mathbf{S}_1 \in \mathbb{R}^{r_1 \times n_1}$ e $\mathbf{S}_2 \in \mathbb{R}^{r_2 \times n_2}$ oblivious (ε, δ) -embedding l_2 di $\mathbb{R}^{n_1}$ e $\mathbb{R}^{n_2}$, rispettivamente. Allora il prodotto di Kronecker $\mathbf{S}_1 \otimes \mathbf{S}_2 \in \mathbb{R}^{r_1 r_2 \times n_1 n_2}$ è un oblivious $(\varepsilon(2 + \varepsilon), 2\delta)$ -embedding l_2 di $\mathbb{R}^{n_1 n_2}$.

Dimostrazione. Notando che $\mathbf{S}_1 \otimes \mathbf{S}_2 = (\mathbf{S}_1 \otimes \mathbf{I}_{r_2})(\mathbf{I}_{n_1} \otimes \mathbf{S}_2)$, si ottiene

$$\|(\mathbf{S}_1 \otimes \mathbf{S}_2)x\|_2 = \|(\mathbf{S}_1 \otimes \mathbf{I}_{r_2})(\mathbf{I}_{n_1} \otimes \mathbf{S}_2)x\|_2 = \|(\mathbf{S}_1 \otimes \mathbf{I}_{r_2})y\|_2,$$

dove $y = (\mathbf{I}_{n_1} \otimes \mathbf{S}_2)x$.

Indichiamo con $(\Omega_1, \mathcal{F}_1, \Pi_1)$ e $(\Omega_2, \mathcal{F}_2, \Pi_2)$ le terne di probabilità per $\mathbf{S}_1$ e $\mathbf{S}_2$, rispettivamente. Poiché $\mathbf{S}_1$ è un oblivious (ε, δ) -embedding l_2 di $\mathbb{R}^{n_1}$, abbiamo con probabilità almeno $1 - \delta$ in Π_1 che

$$\left| \|(\mathbf{S}_1 \otimes \mathbf{I}_{r_2})y\|_2 - \|y\|_2 \right| \leq \varepsilon \|y\|_2.$$

Similmente, con probabilità almeno $1 - \delta$ per la scelta di $\mathbf{S}_2$ in Π_2 , abbiamo

$$\left| \|(\mathbf{I}_{n_1} \otimes \mathbf{S}_2)x\|_2 - \|x\|_2 \right| \leq \varepsilon \|x\|_2 \quad \text{per ogni } x \in \mathbb{R}^{n_1 n_2}.$$

Combinando le due disuguaglianze, abbiamo con probabilità almeno $1 - 2\delta$ nello spazio

di probabilità congiunto di Π_1 e Π_2 che il seguente è vero per ogni $x \in \mathbb{R}^{n_1 n_2}$:

$$\begin{aligned} \left| \|(\mathbf{S}_1 \otimes \mathbf{S}_2)x\|_2 - \|x\|_2 \right| &\leq \left| \|(\mathbf{S}_1 \otimes \mathbf{I}_{r_2})y\|_2 - \|y\|_2 \right| + \left| \|(\mathbf{I}_{n_1} \otimes \mathbf{S}_2)x\|_2 - \|x\|_2 \right| \\ &\leq \varepsilon \|y\|_2 + \varepsilon \|x\|_2 \\ &= \varepsilon \|(\mathbf{I}_{n_1} \otimes \mathbf{S}_2)x\|_2 + \varepsilon \|x\|_2 \leq \varepsilon(2 + \varepsilon) \|x\|_2. \end{aligned}$$

Quindi, $\mathbf{S}_1 \otimes \mathbf{S}_2$ è un $(\varepsilon(2 + \varepsilon), 2\delta)$ -embedding l_2 di $\mathbb{R}^{n_1 n_2}$. $\square$

Proposizione 4.4.2. Siano $\mathbf{S}_1, \mathbf{S}_2 \in \mathbb{R}^{s \times (2d+1)}$ due ϵ -sottospazi di embedding di $\mathbb{R}^{2d+1}$. Allora $\mathbf{S}_i \otimes \mathbf{I}_n$ e $\mathbf{I}_n \otimes \mathbf{S}_i, i = 1, 2$ sono ϵ -sottospazi di embedding di $\mathbb{R}^{n(2d+1)}$ e $\mathbf{S}_1 \otimes \mathbf{S}_2$ è un $\epsilon(2 + \epsilon)$ -sottospazio di embedding di $\mathbb{R}^{(2d+1)^2}$.

Dimostrazione. La dimostrazione segue dal Lemma 4.4.1 e dal Corollario 4.4.1. $\square$

Dopo aver discusso questi risultati è possibile enunciare e dimostrare il seguente Teorema.

Teorema 4.4.1. ([21]) Sia $\mathbf{S}_U \in \mathbb{R}^{s \times n_1}$ un ϵ -sottospazio di embedding per il sottospazio $\mathcal{U} \subseteq \mathbb{R}^{s \times n_1}$ e $\mathbf{S}_V \in \mathbb{R}^{s \times n_2}$ un ϵ -sottospazio di embedding per il sottospazio $\mathcal{V} \subseteq \mathbb{R}^{s \times n_2}$, con $\dim(\mathcal{U}) = \dim(\mathcal{V}) = 2d + 1$. Siano $\mathbf{U}, \mathbf{V}$ matrici aventi come colonne una base ortonormale di $\mathcal{U}$ e $\mathcal{V}$, rispettivamente. Allora, per ogni $\mathbf{R} = \mathbf{U} \mathbf{Z} \mathbf{V}^\top$, abbiamo

$$(1 - \tilde{\epsilon}) \|\mathbf{R}\|_F \leq \|\mathbf{S}_U \mathbf{R} \mathbf{S}_V^\top\|_F \leq (1 + \tilde{\epsilon}) \|\mathbf{R}\|_F \quad (4.9)$$

con $\tilde{\epsilon} = \epsilon(2 + \epsilon)$

Dimostrazione. Usando la forma vettorizzata, per ogni $\mathbf{R}$ abbiamo $\|\mathbf{R}\|_F = \|\text{vec}(\mathbf{R})\|$. Da un calcolo diretto, otteniamo:

$$\|\mathbf{S}_U \mathbf{R} \mathbf{S}_V^\top\|_F = \|(\mathbf{S}_V \mathbf{V} \otimes \mathbf{S}_U \mathbf{U}) \text{vec}(\mathbf{Z})\|$$

Dalla Proposizione 4.4.1 $\mathbf{S}_U \mathbf{U}$ e $\mathbf{S}_V \mathbf{V}$ sono ϵ -sottospazi di embedding di $\mathbb{R}^{2d+1}$, quindi dalla Proposizione 4.4.2 $\mathbf{S}_V \mathbf{V} \otimes \mathbf{S}_U \mathbf{U}$ è un $\tilde{\epsilon}$ -sottospazio di embedding di $\mathbb{R}^{(2d+1)^2}$. Così, si ottiene

$$(1 - \tilde{\epsilon}) \|\text{vec}(\mathbf{Z})\| \leq \|(\mathbf{S}_V \mathbf{V} \otimes \mathbf{S}_U \mathbf{U}) \text{vec}(\mathbf{Z})\| \leq (1 + \tilde{\epsilon}) \|\text{vec}(\mathbf{Z})\|. \quad (4.10)$$

Inoltre, $\|\text{vec}(\mathbf{Z})\| = \|\text{vec}(\mathbf{R})\|$ e $\mathbf{V} \otimes \mathbf{U}$ ha colonne ortonormali. Inserendo ciò in (4.9) si conclude la dimostrazione. $\square$

Osservazione 4.4.1. Tale risultato si può utilizzare nel caso in cui $\mathbf{M} = \mathbf{R}_d^{SK}$. Infatti è possibile riscrivere il residuo nella forma

$$\mathbf{R}_d^{SK} = \mathbf{V}_{2d+1} \mathbf{Z} \mathbf{V}_{2d+1}^\top$$

dove $\mathbf{V}_{2d+1}$ è una matrice avente colonne ortonormali e $\mathbf{Z} \in \mathbb{R}^{(2d+1) \times (2d+1)}$. La strategia è simile a quella in [21].

4.5 L'algoritmo

In questa sezione verrà riportato l'algoritmo descritto nei paragrafi precedenti. Se l'algoritmo termina alla iterazione d , restituisce la base $\widehat{\mathbf{V}}_d$ e la soluzione del problema ridotto $\widehat{\mathbf{Y}}_d$.

Opzionalmente, al convergere, la matrice $\mathbf{T}_d^{-1} \mathbf{Y}_d (\mathbf{T}_d^{-1})^\top$ può essere approssimata mediante una fattorizzazione a basso rango, $\mathbf{T}_d^{-1} \mathbf{Y}_d (\mathbf{T}_d^{-1})^\top \approx \mathbf{Z}^{(1)} (\mathbf{Z}^{(2)})^\top$, con $\mathbf{Z}^{(1)}, \mathbf{Z}^{(2)} \in \mathbb{R}^{dr \times l}$, $l \leq dr$, cosicché la soluzione approssimata finale $\mathbf{X}_d$ è disponibile come prodotto a rango basso $\mathbf{X}_d \approx \mathbf{X}^{(1)} (\mathbf{X}^{(2)})^\top = (\mathbf{V}_d \mathbf{Z}^{(1)}) (\mathbf{V}_d \mathbf{Z}^{(2)})^\top$. Si può utilizzare una tecnica detta a due passi che permette di fare ciò e risparmiare spazio in memoria. (Vedi, ad esempio, [20]).

Metodo	Allocazione di Memoria delle Basi	Soluzione Aproxsimata
Full Arnoldi	$\mathbf{V}_d \quad 2(d+1) \cdot n$	$(\mathbf{X}_d^{\text{full}})^{(1)}, (\mathbf{X}_d^{\text{full}})^{(2)} \quad 2l \cdot n$
STKM	$\widehat{\mathbf{V}}_d \quad 2(k+1) \cdot n$	$\mathbf{X}_d^{(1)}, \mathbf{X}_d^{(2)} \quad 2l \cdot n$

Tabella 4.1. Requisiti di memoria per allocazione della base di Krylov e calcolo soluzione approssimata finale del metodo con Arnoldi completo e dell'algoritmo Sketched.

La Tabella 4.1 riassume i principali requisiti di memoria del metodo completo di Arnoldi e del metodo descritto. Per $k, l \ll d$ la principale differenza tra le due classi

Algorithm 4 Metodo Sketched ed Arnoldi troncato per l'equazione lineare multitermine (4.1)

- 1: **Input:** $\mathbf{A}, \mathbf{M} \in \mathbb{R}^{n \times n}$, $\mathbf{C} \in \mathbb{R}^n$, $\mathbf{S}_V \in \mathbb{R}^{s \times n}$, interi $0 < k \leq \maxit \ll n$, $\text{tol} > 0$, $p \geq 1$
 - 2: **Output:** $\mathbf{Y}, \mathbf{V}$ tale che $\mathbf{X} = \mathbf{V}\mathbf{Y}\mathbf{V}^\top$ è soluzione approssimata di $\mathbf{A}\mathbf{X} + \mathbf{X}\mathbf{A}^\top + \mathbf{M}\mathbf{X}\mathbf{M}^\top = \mathbf{C}\mathbf{C}^\top$
 - 3: Calcola QR ridotta: $\mathbf{V}_1 = \mathbf{C}$, $\mathbf{Q}_{V,1}\beta = \mathbf{S}_V\mathbf{C}$, e imposta $T_{V,1} = \beta$
 - 4: **for** $d = 1$ to $\maxit$ **do**
 - 5: Calcola $v_{2d} = \mathbf{A}\mathbf{V}_d$, $v_{2d+1} = \mathbf{M}^\top \mathbf{V}_d$
 - 6: **for** $i = \max\{1, d - k + 1\}$ to d **do**
 - 7: Calcola $v_{2d} = v_{2d} - V_i h_{i,d}$ con $h_{i,d} = v_i^\top v_{2d}$
 - 8: Calcola $v_{2d+1} = v_{2d+1} - V_i g_{i,d}$ con $g_{i,d} = V_i^\top v_{2d+1}$
 - 9: **end for**
 - 10: Calcola QR ridotta: $[\mathbf{V}_{2d}, \mathbf{V}_{2d+1}]\mathbf{R}_d = [v_{2d}, v_{2d+1}]$
 - 11: Aggiorna QR: $\mathbf{Q}_{V,d+1}\mathbf{T}_{V,d+1} = \mathbf{S}_V[\mathbf{V}_d, \mathbf{V}_{2d}, \mathbf{V}_{2d+1}]$
 - 12: Aggiorna base sketched: $\hat{\mathbf{V}}_{d+1} = [\mathbf{V}_d, \mathbf{V}_{2d}, \mathbf{V}_{2d+1}]\mathbf{T}_{V,d+1}^{-1}$
 - 13: **if** $d \bmod p = 0$ **then**
 - 14: Aggiorna le matrici proiettate $\underline{\mathbf{A}} = \mathbf{Q}_{V,d+1}^\top \mathbf{S}_V \mathbf{A} \hat{\mathbf{V}}_{d+1}$, $\underline{\mathbf{M}} = \mathbf{Q}_{V,d+1}^\top \mathbf{S}_V \mathbf{M} \hat{\mathbf{V}}_{d+1}$ e
 $\underline{\mathbf{C}} = \mathbf{Q}_{V,d+1}^\top \mathbf{S}_V \mathbf{C}$
 - 15: Risolvi l'equazione ridotta $\underline{\mathbf{A}}\mathbf{Y}_d + \mathbf{Y}_d \underline{\mathbf{A}}^\top + \underline{\mathbf{M}}\mathbf{Y}_d \underline{\mathbf{M}}^\top - \underline{\mathbf{C}}\underline{\mathbf{C}}^\top = 0$ in $\mathbf{Y}_d$
 - 16: Calcola $\rho = \|\mathbf{S}_V \mathbf{R}_d^{SK} \mathbf{S}_V^\top\|_F$
 - 17: **if** $\rho < \text{tol}$ **then**
 - 18: **Termina**
 - 19: **end if**
 - 20: **end if**
 - 21: **end for**
-

di metodi risiede nelle allocazioni di memoria per le basi generate. D'altro canto, lo spazio richiesto per i fattori della soluzione dipende dalle proprietà di decadimento spettrale della soluzione del problema ridotto. Poiché lo spazio polinomiale di Krylov genera informazioni ridondanti, il rango numerico l di $\mathbf{Y}_d$ può essere significativamente inferiore alla sua dimensione, consentendo notevoli risparmi nella memorizzazione della soluzione approssimata in forma fattorizzata.

4.6 Esperimenti numerici

In questa sezione verranno riportati alcuni esperimenti numerici simili a quelli descritti in [29]. In tutti gli esperimenti lo sketching è rappresentato come

$$\mathbf{S} = \sqrt{s/n} \cdot \mathbf{PCD} \in \mathbb{R}^{s \times n}$$

dove le matrici sono prese come nell'Osservazione 3.3.1. Per tale trasformazione è stato dimostrato in [31] che è necessaria una dimensione di sketching $s = O(d \log d)$ dove d indica la dimensione dello spazio finale di approssimazione, mentre prove pratiche suggeriscono che in molte situazioni $s = O(d)$ sia sufficiente. Poiché le costanti nascoste nella O dipendono quadraticamente dalla distorsione ε , è necessario lavorare con accuratèzze piuttosto approssimative, ad esempio $\varepsilon = \frac{1}{\sqrt{2}}$. In questi esperimenti verrà confrontato il nuovo metodo descritto nelle sezioni precedenti con il metodo della sezione 4.1 basato su Gradienti Coniugati orientato alle matrici. Nel primo metodo il calcolo del residuo verrà sostituito con il calcolo della quantità $\|\mathbf{S}\mathbf{R}_d^{SK}\mathbf{S}^\top\|_F$ grazie al teorema 4.4.1 mentre nel secondo verrà calcolato esplicitamente utilizzando una decomposizione della forma (4.7).

Nel metodo sketched, la soluzione del problema proiettato verrà ottenuta utilizzando il GMRES con restart. La macchina utilizzata per l'esecuzione dell'algoritmo in linguaggio MATLAB ha le seguenti specifiche tecniche:

- Costruttore: Apple
- Modello: MacBookAir10,1
- Processore: Apple M1

- RAM: 8GB
- Sistema operativo: macOS 14.5

L'obiettivo è evidenziare la differenza in termini di tempo tra i due algoritmi. In entrambi gli esperimenti si considerano dimensioni delle matrici che ammettono radice quadrata intera positiva.

Esempio 4.6.1. Data l'equazione (4.1) si considerano $\mathbf{A}, \mathbf{M} \in \mathbb{R}^{n \times n}$ e $\mathbf{C} \in \mathbb{R}^n$ così costruiti:

- $\mathbf{A} = \mathbf{P}_n + 2\mathbf{I}_n$ dove $\mathbf{P}_n$ è la matrice di Poisson 2D di dimensione $n \times n$ così definita:

$$\mathbf{A} = \mathbf{T} \otimes \mathbf{I}_l + \mathbf{I}_l \otimes \mathbf{T}, \quad (4.11)$$

con $\mathbf{T} = \text{Toeplitz}([2, -1, O_{1,l-2}]) \in \mathbb{R}^{l \times l}$ e $l = \sqrt{n}$.


- $\mathbf{M} = \text{Toeplitz}([3.2, -1, -0.5, O_{1,n-3}]) \in \mathbb{R}^{n \times n}$
- $\mathbf{C} = \mathbf{1}_n \in \mathbb{R}^n$ vettore avente come elementi 1.

Nella Tabella 4.2 si confronteranno il metodo Full Arnoldi con Gradienti Coniugati e il metodo con sketching e troncato (STKM) al variare di n con parametri fissi maxit= 100, $s = 200$, tol= 10^{-5} e parametro di troncamento $k = 3$.

n	Full Arnoldi			STKM		
	d	res	time	d	res	time
184900	33	9.87e-6	3.99	33	9.37e-6	0.87
280900	33	8.29e-6	6.36	33	7.69e-6	1.33
532900	33	6.34e-6	13.4	33	5.45e-6	3.96

Tabella 4.2. Prestazioni del metodo Arnoldi completo e del metodo STKM. I tempi di CPU riportati sono in secondi. "res" indica il residuo finale e d indica la dimensione finale dello spazio di Krylov

Come si evince dalla tabella, entrambi i metodi convergono alla stessa iterazione. L'unica differenza sostanziale sta nei tempi di esecuzione dove si nota che il metodo Sketched and Truncated è più veloce rispetto al metodo Full Arnoldi.


 Figura 4.1. Storia del residuo dei due metodi per $n = 280900,532900$.

Dai due grafici in Figura 4.1 si può notare che la convergenza del residuo è la stessa per entrambi i metodi.

Esempio 4.6.2. Siano ora $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{n \times n}$ e $\mathbf{C} \in \mathbb{R}^n$ così costruiti:

- $\mathbf{A} = \mathbf{P}_n + 8\mathbf{I}_n$ dove $\mathbf{P}_n$ è la matrice di Poisson 2D di dimensione $n \times n$ definita come in (4.11).

$$\bullet \mathbf{M} = \begin{bmatrix} 3 + 2r_1 & -1 & 0 & \cdots & 0 \\ -1 & 3 + 2r_2 & -1 & \cdots & 0 \\ \vdots & & \ddots & \ddots & -1 \\ 0 & \cdots & \cdots & -1 & 3 + 2r_n \end{bmatrix} \in \mathbb{R}^{n \times n}$$

dove r_j valore random in $(0,1)$ preso con distribuzione normale standard.

- $\mathbf{C} = (s_j)_{j=1,\dots,n} \in \mathbb{R}^n$ dove $s_j \in (0,1)$ valore presi con distribuzione normale standard

Nella Tabella 5.1 si confronteranno i due metodi al variare di n con parametri fissi $\text{maxit} = 220$, $s = 881$, $\text{tol} = 10^{-6}$ e parametro di troncamento $k = 3$.

Come si evince dalla tabella, entrambi i metodi convergono alla stessa iterazione.

n	Full Arnoldi			STKM		
	d	res	time	d	res	time
902500	71	8.77e-7	145	79	8.42e-7	15.3
1000000	63	5.27e-7	123	63	5.93e-7	12
1060900	71	9.83e-7	183	71	9.83e-7	20

Tabella 4.3. Prestazioni del metodo Arnoldi completo e del metodo sketched and truncated. I tempi di CPU riportati sono in secondi. "res" indica il residuo finale e d indica la dimensione finale dello spazio di Krylov.

L'unica differenza sostanziale sta nei tempi di esecuzione dove si nota che il metodo STKM è più veloce rispetto al metodo Full Arnoldi.




Figura 4.2. Storia del residuo dei due metodi per $n = 90000, 144400$.

Dai due grafici in Figura 4.2 si può notare che il comportamento del residuo per entrambi i metodi è praticamente lo stesso.

Capitolo 5

Metodo Sketched ed Arnoldi troncato su spazi di Krylov: caso multitermine

In questo capitolo consideriamo la procedura introdotta nel capitolo 4 per l'approssimazione della soluzione della equazione nella forma:

$$\mathbf{A}_0 \mathbf{X} \mathbf{B}_0^\top + \mathbf{A}_1 \mathbf{X} \mathbf{B}_1^\top + \cdots + \mathbf{A}_m \mathbf{X} \mathbf{B}_m^\top = \mathbf{C}_1 \mathbf{C}_2^\top, \quad (5.1)$$

dove $\mathbf{A}_i \in \mathbb{R}^{n \times n}$, $\mathbf{B}_j \in \mathbb{R}^{m \times m}$ sono matrici simmetriche definite positive sparse, $\mathbf{C}_1 \in \mathbb{R}^n$, $\mathbf{C}_2 \in \mathbb{R}^m$ e $\mathbf{X} \in \mathbb{R}^{n \times m}$ è soluzione dell'equazione matriciale e in generale si considererà $n \gg m$. Questi tipi di equazioni possono provenire per esempio dalla discretizzazione di PDEs stocastiche. Le matrici $\mathbf{A}_i$ come si vedrà vengono dalla discretizzazione di componenti dipendenti dallo spazio mentre le matrici $\mathbf{B}_i$ vengono dalla discretizzazione di funzioni stocastiche. Inizialmente verranno introdotti gli spazi di Krylov razionali come spazi di approssimazione e poi la strategia vista nel capitolo 4 basata su spazi di Krylov polinomiali e gli ϵ -sottospazi di embedding applicata a (5.1). Infine, verrà effettuato un confronto tra due metodi basati su tali strategie.

5.1 Metodo con sottospazi di Krylov razionali

Come visto in precedenza, i sottospazi di Krylov polinomiali si sono dimostrati spazi di approssimazione efficaci nei metodi di proiezione per equazioni matriciali lineari.

Tuttavia, un limite di tali sottospazi è che possono richiedere una grande dimensione per approssimare in modo soddisfacente la soluzione cercata. L'uso dei sottospazi di Krylov razionali, che coinvolgono funzioni razionali di matrici del tipo $(\mathbf{A} + s_j \mathbf{I})^{-1}$, con $s_j \in \mathbb{C}$, ha praticamente risolto questo problema in molte applicazioni. A fronte della necessità di risolvere un sistema lineare a ogni iterazione, lo spazio generato acquisisce rapidamente informazioni spettrali della matrice $\mathbf{A}$, permettendo così una buona approssimazione in uno spazio di dimensione inferiore rispetto ai sottospazi di Krylov polinomiali classici. I sottospazi di Krylov razionali, con parametri s_j scelti appropriatamente, sono quindi diventati uno standard nella risoluzione di equazioni di grande scala e di altri problemi come le valutazioni di funzioni di matrici.

Definizione 5.1.1. Sia $\mathbf{A}_r \in \mathbb{R}^{n \times n}$, $v_0 \in \mathbb{R}^n$ e $s = [s_1, s_2, \dots]$. Si definisce

$$\mathbb{K}_l(\mathbf{A}_r, v_0, s) := \text{range}\{v_0, (\mathbf{A}_r + s_{r_1} \mathbf{I})^{-1} v_0, \dots, \prod_{j=1}^l (\mathbf{A}_r + s_{r_j} \mathbf{I})^{-1} v_0\} \quad (5.2)$$

il sottospazio razionale di Krylov associato alla matrice $\mathbf{A}_r$, al vettore v_0 e al vettore di parametri s , dove $[s_{r_1}, s_{r_2}, \dots, s_{r_l}]$ è un sottoinsieme opportuno di l elementi di s .

In seguito si riporta un'estensione dell'idea di tali sottospazi basata sulla trattazione in [23].

Per introdurre il concetto di approssimazione ridotta con sottospazio di Krylov razionale, si supponga di avere un insieme di m matrici simmetriche definite positive sparse $\mathbf{A}_1, \dots, \mathbf{A}_m$ di dimensione $n \times n$, i cui spettri sono tutti contenuti in un piccolo intervallo $\mathcal{S} \subset \mathbb{R}^+$ (l'importanza di tale ipotesi è evidenziata in [23]). Inoltre, sia $\mathbf{A}_0 = \mathbf{I}_n$, dove $\mathbf{I}_n$ è la matrice identità di dimensione $n \times n$ (per semplicità in seguito si indicherà con $\mathbf{I}$). Ora si supponga di voler risolvere una generica equazione matriciale della forma (5.1) per la matrice incognita $\mathbf{X}$. In questa sezione, consideriamo (5.1) come un problema astratto, tralasciando temporaneamente i dettagli specifici delle equazioni matriciali Galerkin stocastiche.

Supponiamo di poter generare una base ortonormale per uno spazio di approssimazione $\mathcal{K}_k \subset \mathbb{R}^n$ di dimensione $n_k \ll n$. Se raccogliamo gli n_k vettori base in una matrice $\mathbf{V}_k$ di dimensione $n \times n_k$, allora una soluzione approssimata di (5.1) può essere

cercata nella forma $\mathbf{X}_k = \mathbf{V}_k \mathbf{Y}_k \approx \mathbf{X}$, dove la matrice $\mathbf{Y}_k$ di dimensione $n_k \times m$ (la soluzione ridotta) può essere definita imponendo che il residuo

$$\mathbf{R}_k := \mathbf{X}_k \mathbf{B}_0 + \mathbf{A}_1 \mathbf{X}_k \mathbf{B}_1 + \cdots + \mathbf{A}_m \mathbf{X}_k \mathbf{B}_m - \mathbf{C}_1 \mathbf{C}_2^\top$$

soddisfi la condizione di Galerkin $\mathbf{V}_k^\top \mathbf{R}_k = 0$. L'equazione ridotta sarà:

$$(\mathbf{V}_k^\top \mathbf{V}_k) \mathbf{Y}_k \mathbf{B}_0 + (\mathbf{V}_k^\top \mathbf{A}_1 \mathbf{V}_k) \mathbf{Y}_k \mathbf{B}_1 + \cdots + (\mathbf{V}_k^\top \mathbf{A}_m \mathbf{V}_k) \mathbf{Y}_k \mathbf{B}_m = \mathbf{V}_k^\top \mathbf{C}_1 \mathbf{C}_2^\top. \quad (5.3)$$

Rispetto al capitolo precedente, si suppone che $\mathbf{W}_k = \mathbf{I}$. Confrontando (5.2) con (5.1) vediamo che le matrici a sinistra sono state ridotte in dimensione (da $n \times n$ a $n_k \times n_k$) ma saranno dense piuttosto che sparse. Le matrici a destra $\mathbf{B}_r$ restano invariate.

Osservazione 5.1.1. Come visto nel capitolo precedente, utilizzando la formulazione di Kronecker, (5.2) è equivalente al sistema algebrico $\mathcal{A}_k y_k = b_k$, dove $y_k = \text{vec}(\mathbf{Y}_k)$, $b_k = \mathbf{V}_k^\top \mathbf{C}_1 \otimes \mathbf{C}_2$ e

$$\mathcal{A}_k = \mathbf{I}_{n_k} \otimes \mathbf{B}_0 + (\mathbf{V}_k^\top \mathbf{A}_1 \mathbf{V}_k) \otimes \mathbf{B}_1 + \cdots + (\mathbf{V}_k^\top \mathbf{A}_m \mathbf{V}_k) \mathbf{Y}_k \mathbf{B}_m.$$

Per costruire gli spazi $\mathcal{K}_j$ si procede come nel seguente schema. Alla prima iterazione $j = 1$, si parte con $\mathbf{V}_0 = \mathbf{v}_0 = \mathbf{C}_1 / \|\mathbf{C}_1\|_2 \in \mathbb{R}^n$ e si calcola

$$\mathbf{W} = [(\mathbf{A}_1 + s_1 \mathbf{I})^{-1} \mathbf{v}_0, \dots, (\mathbf{A}_m + s_1 \mathbf{I})^{-1} \mathbf{v}_0] \in \mathbb{R}^{n \times m}.$$

Successivamente, si selezionano le $l_1 \leq m$ direzioni più significative di questa matrice. Questo viene fatto calcolando i valori singolari σ_i di $\mathbf{W}$ e mantenendo solo gli l_1 vettori singolari u_i , $i = 1, \dots, l_1$ con l_1 scelto in modo tale che

$$\sum_{i=1}^{l_1} \sigma_i > \frac{\beta}{100} \sum_{i=1}^m \sigma_i \quad (5.4)$$

dove β è un parametro di proporzione dichiarato prima della procedura (tipicamente $\beta = 99$).

Lo spazio di approssimazione $\mathcal{K}_1$ avrà dimensione $n_1 = l_1 + 1 \leq m + 1$ ed è dato da $\text{range}(V_1)$, una volta che i vettori sono stati modificati per formare una base ortonormale $V_1 = \text{orth}([v_0, u_1, \dots, u_{l_1}]) = [v_0, v_1, \dots, v_{l_1}] \in \mathbb{R}^{n \times (l_1+1)}$. La seconda iterazione è definita calcolando una nuova matrice

$$\mathbf{W} = [(\mathbf{A}_1 + s_2 \mathbf{I})^{-1} v_1, \dots, (\mathbf{A}_m + s_2 \mathbf{I})^{-1} v_1, \dots, (\mathbf{A}_1 + s_2 \mathbf{I})^{-1} v_{l_1}, \dots, (\mathbf{A}_m + s_2 \mathbf{I})^{-1} v_{l_1}] \in \mathbb{R}^{n \times m l_1} \quad (5.5)$$

e, analogamente a prima, si selezionano le l_2 direzioni principali per generare $\mathcal{K}_2 = \text{range}(V_2)$, con dimensione $n_2 = 1 + l_1 + l_2$.

Si itera il processo fino al completamento, terminando dopo k iterazioni quando la dimensione di $\mathcal{K}_k$ supera la dimensione massima disponibile o la soluzione stimata soddisfa un criterio di convergenza.

Osservazione 5.1.2. Il vettore $s = [s_1, s_2, \dots]$ è selezionato prima che l'iterazione incominci. Si osserva che siccome $\mathbf{A}_r$ è simmetrica e definita positiva, ogni matrice $(\mathbf{A}_r + s_j \mathbf{I})$, $r = 1, \dots, m$ è invertibile, a prescindere dalla scelta di s se $\text{Im}(s_j) \neq 0$. Per approfondimenti su eventuali scelte di s si rimanda a [23].

Osservazione 5.1.3. Dopo k iterazioni, lo spazio di approssimazione di Krylov generato nell'algoritmo contiene gli spazi di Krylov razionali $\mathbb{K}_l(\mathbf{A}_r, v_0, s)$, $r = 1, \dots, m$ per particolari valori di l (vedi, per esempio, [23]).

Esempio 5.1.1. Si considera il caso in cui si hanno 4 termini in (5.1). Si supponga che s_1, s_2 e s_3 siano distinti. Il processo descritto in precedenza genera il seguente sottospazio:

$$\begin{aligned} \text{range}\{ & v_0, (\mathbf{A}_1 + s_1 \mathbf{I})^{-1} v_0, (\mathbf{A}_2 + s_1 \mathbf{I})^{-1} v_0, (\mathbf{A}_3 + s_1 \mathbf{I})^{-1} v_0, \\ & (\mathbf{A}_1 + s_2 \mathbf{I})^{-1} v_0, (\mathbf{A}_2 + s_2 \mathbf{I})^{-1} v_0, (\mathbf{A}_3 + s_2 \mathbf{I})^{-1} v_0, \\ & (\mathbf{A}_1 + s_3 \mathbf{I})^{-1} v_0, (\mathbf{A}_2 + s_3 \mathbf{I})^{-1} v_0, (\mathbf{A}_3 + s_3 \mathbf{I})^{-1} v_0 \} \end{aligned}$$

. Si osserva che tale spazio contiene i sottospazi

$$\begin{aligned}\mathbb{K}_2(\mathbf{A}_1, v_0, s) &= \text{range}\{v_0, (\mathbf{A}_1 + s_1 \mathbf{I})^{-1} v_0, (\mathbf{A}_1 + s_2 \mathbf{I})^{-1} (\mathbf{A}_1 + s_1 \mathbf{I})^{-1} v_0\}, \\ \mathbb{K}_2(\mathbf{A}_2, v_0, s) &= \text{range}\{v_0, (\mathbf{A}_2 + s_1 \mathbf{I})^{-1} v_0, (\mathbf{A}_2 + s_3 \mathbf{I})^{-1} (\mathbf{A}_2 + s_1 \mathbf{I})^{-1} v_0\}\end{aligned}$$

associati a $\mathbf{A}_1$ e $\mathbf{A}_2$ e il sottospazio

$$\mathbb{K}_1(\mathbf{A}_3, v_0, s) = \text{range}\{v_0, (\mathbf{A}_3 + s_1 \mathbf{I})^{-1} v_0\}$$

associato a $\mathbf{A}_3$

5.2 Metodo sketched Galerkin: caso multitermine

Applichiamo al problema (5.1) la strategia vista nel quarto capitolo. Gli spazi di approssimazione che si considereranno, denotati con $\mathcal{K}_d(\mathbf{A}_1, \mathbf{A}_2, \dots, \mathbf{A}_m, C_1)$, saranno generati nella seguente maniera:

$$\left\{ \begin{array}{l} V_0 = C_1 / \|C_1\|_2 =: \underline{v}_0 \\ V_1 = [v_0, \mathbf{A}_1 v_0, \dots, \mathbf{A}_m v_0] =: [v_0, \underline{v}_1, \dots, v_m] \\ V_2 = [V_1, \mathbf{A}_1 v_1, \dots, \mathbf{A}_m v_1] =: [v_0, v_1, \underline{v}_2, \dots, v_{2m}] \\ \dots \end{array} \right. \quad (5.6)$$

assumendo come in precedenza che $\mathbf{A}_0 = \mathbf{I}$.

Osservazione 5.2.1. Assumendo che la matrice calcolata abbia rango massimo, il sottospazio generato ha dimensione $\dim(\text{range}(V_k)) = mk + 1$, $k = 0, 1, \dots$

Osservazione 5.2.2. Le proprietà viste per gli spazi di approssimazione dello scorso capitolo possono essere generalizzate anche a questo caso con calcoli più complessi ma analoghi.

Si considera ora $\mathbf{S}_V \in \mathbb{R}^{s \times n}$ un ϵ -sottospazio di embedding e si suppone che $\mathbf{V}_d$ sia la matrice avente come colonne una base ortonormale per V_d . Sia $\mathbf{S}_V \mathbf{V}_d = \mathbf{Q}_d \mathbf{T}_d$ la fattorizzazione QR di $\mathbf{S}_V \mathbf{V}_d$. Ad ogni iterazione lo scopo è trovare una soluzione per

(5.1) della forma $\mathbf{X}_d = \widehat{\mathbf{V}}_d \mathbf{Y}_d$ dove $\widehat{\mathbf{V}}_d = \mathbf{V}_d \mathbf{T}_d^{-1} \in \mathbb{R}^{n \times md+1}$ e $\mathbf{Y}_d \in \mathbb{R}^{md+1 \times md+1}$ è la soluzione ridotta calcolata imponendo la condizione di Galerkin sul residuo di (5.1) in forma sketching ad un lato, ovvero:

$$\widehat{\mathbf{V}}_d^\top \mathbf{S}_V^\top \mathbf{S}_V \mathbf{R}_d^{SK} = 0 \quad (5.7)$$

dove:

$$\mathbf{R}_d^{SK} = \mathbf{A}_0 \mathbf{X}_d \mathbf{B}_0^\top + \mathbf{A}_1 \mathbf{X}_d \mathbf{B}_1^\top + \cdots + \mathbf{A}_m \mathbf{X}_d \mathbf{B}_m^\top - \mathbf{C}_1 \mathbf{C}_2^\top. \quad (5.8)$$

Esplicitando i conti nel membro di sinistra in (5.7) e sfruttando il fatto che $\mathbf{S}_V \widehat{\mathbf{V}}_d = \mathbf{Q}_d$ matrice ortogonale per costruzione allora si ottiene la seguente equazione:

$$\mathbf{Y}_d \mathbf{B}_0 + \widehat{\mathbf{V}}_d^\top \mathbf{S}_V^\top \mathbf{S}_V \mathbf{A}_1 \mathbf{Y}_d \mathbf{B}_1 + \cdots + \widehat{\mathbf{V}}_d^\top \mathbf{S}_V^\top \mathbf{S}_V \mathbf{A}_m \mathbf{Y}_d \mathbf{B}_m - \widehat{\mathbf{V}}_d^\top \mathbf{S}_V^\top \mathbf{S}_V \mathbf{C}_1 \mathbf{C}_2^\top = 0 \quad (5.9)$$

assumendo che $\mathbf{A}_0 = \mathbf{I}$.

Osservazione 5.2.3. Come visto in precedenza, è possibile adottare una tecnica di troncamento per ridurre il costo del passo di ortogonalizzazione.

L'algoritmo 5 descrive la procedura completa.

5.3 Esperimenti numerici

In questa sezione si andranno a confrontare il metodo con sketching con il metodo descritto in [23] basato su spazi di Krylov razionali (si veda l'Appendice B per l'algoritmo). Le equazioni matriciali prese in esame vengono dalla discretizzazione di PDEs stocastiche della forma

$$-\nabla \cdot (a(\vec{x}, \omega) \nabla u(\vec{x}, \omega)) = f(\vec{x}) \quad \text{in } D, \quad u(\vec{x}, \omega) = 0 \quad \text{sul } \partial D \quad (5.10)$$

dove $D \subset \mathbb{R}^2$ è un dominio spaziale sufficientemente regolare, Ω uno spazio campionario associato a uno spazio di probabilità $(\Omega, \mathcal{F}, \mathbb{P})$, f funzione deterministica e a un campo random che può essere espresso come una funzione lineare di un numero finito di

Algorithm 5 Algoritmo con sketching

Require: le matrici $\{\mathbf{A}_r\}_{r=1,2,\dots,m}$ e $\{\mathbf{B}_r\}_{r=0,1,\dots,m}$, i vettori f_0 e g_0 , i parametri s (dimensione delle righe della matrice di sketching $\mathbf{S}$) e k (parametro di troncamento di Arnoldi), β (la soglia di troncamento), e $j_{\max}$ il numero massimo di iterazioni.

- 1: $v = f_0/\|f_0\|$, $\mathbf{V}_0 = v$, $j = 1$
 - 2: **while** non convergente e $j < j_{\max}$ **do**
 - 3: Calcola $\mathbf{W} = [\mathbf{A}_1 v, \dots, \mathbf{A}_m v]$ e tronca $\mathbf{W} \leftarrow \text{trunc}(\mathbf{W}) \in \mathbb{R}^{n_x \times l_j}$
 - 4: Ortogonalizza $\mathbf{W}$ rispetto agli ultimi k vettori di $\mathbf{V}_{j-1}$ e aumenta $\mathbf{V}_j \leftarrow [\mathbf{V}_{j-1}, \text{orth}(\mathbf{W})]$
 - 5: Aggiorna QR: $\mathbf{Q}_{\mathbf{V},j} \mathbf{T}_{\mathbf{V},j} = \mathbf{S}_{\mathbf{V}}[\mathbf{V}_{j-1}, \mathbf{W}]$
 - 6: Aggiorna base sketched: $\hat{\mathbf{V}}_j = [\mathbf{V}_{j-1}, \mathbf{W}] \mathbf{T}_{\mathbf{V},j}^{-1}$
 - 7: Aggiorna le matrici proiettate $\underline{\mathbf{A}}_r = \mathbf{Q}_{\mathbf{V},j}^\top \mathbf{S} \mathbf{A}_r \hat{\mathbf{V}}_j$, $r = 1, \dots, m$, $\underline{f} = \mathbf{Q}_{\mathbf{V},j}^\top \mathbf{S} f_0$
 - 8: Risolvi approssimativamente $\mathbf{Y}_j \mathbf{B}_0 + (\underline{\mathbf{A}}_1 \mathbf{Y}_j \mathbf{B}_1 + \dots + \underline{\mathbf{A}}_m \mathbf{Y}_j \mathbf{B}_m) = \underline{f} g_0^\top$ e verifica la convergenza
 - 9: **if** il criterio di arresto è soddisfatto **then**
 - 10: Imposta $k = j$ e termina
 - 11: **else**
 - 12: Imposta $v = \mathbf{V}_j e_{j+1}$ (usa la colonna successiva di $\mathbf{V}_j$ per aumentare lo spazio)
 - 13: Imposta $j = j + 1$
 - 14: **end if**
 - 15: **end while**
-

variabili casuali indipendenti $\xi_r : \Omega \rightarrow \Gamma_r \subset \mathbb{R}$ della forma

$$a(\vec{x}, \omega) = a_0(\vec{x}) + \sum_{r=1}^m a_r(\vec{x}) \xi_r(\omega) \quad (5.11)$$

Osservazione 5.3.1. Una scelta comune per $a(\vec{x}, \omega)$ è uno sviluppo di Karhunen–Loève (KL) troncato (vedi [16] per ulteriori discussioni). In tal caso,

$$a(\vec{x}, \omega) = \mu(\vec{x}) + \sigma \sum_{r=1}^m \sqrt{\lambda_r} \phi_r(\vec{x}) \xi_r(\omega), \quad (5.12)$$

dove μ è il valore atteso del coefficiente di diffusione, σ è la deviazione standard, e $\{\lambda_r, \phi_r\}$ con $\lambda_1 \geq \lambda_2 \geq \dots$ sono coppie di autovalori e autofunzioni dell'operatore integrale B associato a

$$B(\vec{x}_1, \vec{x}_2) = \frac{1}{\sigma^2} C(\vec{x}_1, \vec{x}_2),$$

dove $C : D \times D \rightarrow \mathbb{R}$ è la funzione di covarianza.

Lo scopo è approssimare $u : D \times \Omega \rightarrow \mathbb{R}$ che soddisfi (5.10) con probabilità $\mathbb{P}$ -quasi certa. I metodi di Galerkin stocastici (introdotti da Babuška e collaboratori [3], [7]) cercano approssimazioni u_{hp} della soluzione debole u di (5.10) in spazi di approssimazione di dimensione finita della forma $Z_h \otimes S_p$, dove $Z_h \subset H_0^1(D)$ e $S_p \subset L_\rho^2(\Gamma)$. Le formulazioni deboli di (5.10) sono state ampiamente studiate nella letteratura (ad esempio, vedi [16, Capitolo 9]) e la buona positura segue direttamente dal Lemma di Lax-Milgram se a è positivo e limitato. Per garantire ciò, ci limitiamo a considerare variabili aleatorie uniformi indipendenti ξ_r su $\Gamma_r = [-1, 1]$ e assumiamo che esistano costanti $a_0^{\min}$ e $a_0^{\max}$ che soddisfano:

$$0 < a_0^{\min} \leq a_0(\vec{x}) \leq a_0^{\max} < \infty \quad \text{q.d. in } D,$$

e funzioni coefficienti a_r che soddisfano:

$$\sum_{r=1}^m \|a_r\|_\infty < a_0^{\min}$$

Qui, $H_0^1(D)$ è lo spazio di Sobolev delle funzioni a valori reali che sono nulle sul bordo

di D , e $L_\rho(\Gamma)$ denota lo spazio delle funzioni su $\Gamma = \Gamma_1 \times \cdots \times \Gamma_m = [-1,1]^m$ che soddisfano:

$$\langle v, v \rangle_\rho := \int_\Gamma \rho(y) v(y)^2 dy < \infty,$$

con $\rho(y) = 2^{-m}$, che è la densità congiunta delle variabili casuali indipendenti $\xi_r(\omega)$, e $y = [y_1, \dots, y_m]$, dove $y_r = \xi_r(\omega)$.

Per approssimare la soluzione, scegliamo $Z_h = \text{span}\{\phi_1(\vec{x}), \dots, \phi_{n_x}(\vec{x})\}$, lo spazio degli elementi finiti associato a una discretizzazione spaziale del dominio D , e $S_p = \text{span}\{\psi_1(y), \dots, \psi_{n_\xi}(y)\}$, l'insieme dei polinomi multivariati di grado al più p su Γ . Negli esperimenti, si utilizzano polinomi di Legendre multivariati, che sono ortonormali rispetto a $\rho(y)$. Il numero di funzioni di base nel prodotto tensoriale è dato da:

$$n_\xi = \frac{(m+p)!}{m!p!},$$

e le funzioni di base sono costruite come:

$$\psi_j(y) = \prod_{s=1}^m \psi_{j_s}(y_s), \quad j = (j_1, \dots, j_m), \quad 0 \leq j_s \leq p,$$

dove $\psi_{j_s}(y_s)$ sono polinomi di Legendre univariati. L'espansione del coefficiente $a(\vec{x}, \omega)$ e la struttura dello spazio di approssimazione $Z_h \otimes S_p$ portano a un sistema algebrico lineare del tipo $\mathcal{A}x = b$, con $n_x \cdot n_\xi$ equazioni. Il sistema matriciale risultante ha la forma:

$$\mathcal{A} = \mathbf{G}_0 \otimes \mathbf{K}_0 + \sum_{r=1}^m \mathbf{G}_r \otimes \mathbf{K}_r, \quad b = g_0 \otimes f_0.$$

Le matrici $\mathbf{K}_0$ e $\mathbf{K}_r$ (di dimensione $n_x \times n_x$) sono le cosiddette matrici di rigidità degli elementi finiti, definite come:

$$[\mathbf{K}_0]_{i,j} = \int_D a_0 \nabla \phi_i \cdot \nabla \phi_j d\vec{x}, \quad [\mathbf{K}_r]_{i,j} = \int_D a_r \nabla \phi_i \cdot \nabla \phi_j d\vec{x}, \quad r = 1, \dots, m.$$

Le matrici $\mathbf{G}_0$ e $\mathbf{G}_r$ (di dimensione $n_\xi \times n_\xi$) rappresentano le componenti stocastiche,

e sono definite come:

$$[\mathbf{G}_0]_{s,t} = \langle \psi_s, \psi_t \rangle_\rho, \quad [\mathbf{G}_r]_{s,t} = \langle y_r \psi_s, \psi_t \rangle_\rho, \quad r = 1, \dots, m.$$

Dato che le funzioni di base sono ortonormali rispetto a $\langle \cdot, \cdot \rangle_\rho$, si ha $\mathbf{G}_0 = I$, mentre il vettore g_0 è la prima colonna di $\mathbf{G}_0$. Il termine f_0 rappresenta la discretizzazione dell'elemento deterministico $f(\vec{x})$ così definito:

$$[f_0]_i = \int_D f \phi_i d\vec{x}.$$

Introducendo la matrice soluzione

$$\mathbf{X} = [x_1, x_2, \dots, x_{n_\xi}] \in \mathbb{R}^{n_x \times n_\xi},$$

la cui j -esima colonna è il sottovettore della soluzione x del sistema lineare contenente i coefficienti associati alla j -esima funzione base ψ_j per S_p , il sistema lineare può anche essere riscritto come un'equazione lineare di matrici:

$$\mathbf{K}_0 \mathbf{X} \mathbf{G}_0 + \sum_{r=1}^m \mathbf{K}_r \mathbf{X} \mathbf{G}_r = f_0 g_0^\top.$$

Ciascun termine corrisponde a un diverso termine nello sviluppo del coefficiente di diffusione (5.11). Le matrici $\mathbf{K}_r$ e $\mathbf{G}_r$ per $r = 0, \dots, m$ sono simmetriche. Inoltre, $\mathbf{G}_1, \dots, \mathbf{G}_m$ hanno al massimo due elementi non nulli per riga. Si può anche dimostrare che gli autovalori di $\mathbf{G}_r$ sono contenuti in $[-1, 1]$ per $r = 1, 2, \dots, m$. Rimandiamo a [23] per ulteriori discussioni.

La matrice $\mathbf{K}_0$ è sempre definita positiva per costruzione. Tuttavia, $\mathbf{K}_1, \dots, \mathbf{K}_m$ sono indefinite quando le funzioni $a_1, \dots, a_m$ non sono strettamente positive. I limiti spettrali per $\mathbf{K}_r$, per $r = 0, 1, \dots, m$, sono dati in [24], e questi dipendono in modo sfavorevole dal parametro di griglia ad elementi finiti h e quindi in particolare dalla dimensione n_x . Per generare un'equazione matriciale del tipo (5.1) che abbia matrici a sinistra definite positive i cui intervalli spettrali non crescano all'aumentare della discretizzazione, si apportano delle modifiche.

In primo luogo, si divide da sinistra (5.10) per $\mathbf{K}_0$. Poiché $\mathbf{K}_0$ è simmetrica e definita positiva, si sfrutta la fattorizzazione di Cholesky $\mathbf{K}_0 = \mathbf{L}\mathbf{L}^\top$ per effettuare la divisione per $\mathbf{L}^{-1}$. Ciò che si ottiene sarà un'equazione della forma

$$\widehat{\mathbf{X}} + \sum_{r=1}^m \widehat{\mathbf{K}}_r \widehat{\mathbf{X}} \mathbf{G}_r = \widehat{f}_0 g_0^\top, \quad (5.13)$$

dove $\widehat{f} := \mathbf{L}^{-1}f$ e $\widehat{\mathbf{K}}_r := \mathbf{L}^{-1}\mathbf{K}_r\mathbf{L}^{-T}$ per $r = 1, \dots, m$. Se $\mathbf{K}_r$ è indefinita, anche $\widehat{\mathbf{K}}_r$ è indefinita. Gli autovalori di $\widehat{\mathbf{K}}_r$ si trovano in un intervallo limitato $[-C_r, C_r]$ con $C_r > 0$. Inoltre applicando uno shift α_r opportuno tale che le matrici $\widehat{\mathbf{K}}_r + \alpha_r \mathbf{I}$ per $r = 1, \dots, m$ sono definite positive, si ottiene la seguente equazione matriciale

$$\widehat{\mathbf{X}}_r \left(\mathbf{I} - \sum_{r=1}^m \alpha_r \mathbf{G}_r \right) + \sum_{r=1}^m \left(\widehat{\mathbf{K}}_r + \alpha_r \mathbf{I} \right) \widehat{\mathbf{X}}_r \mathbf{G}_r = \widehat{f}_0 g_0^\top, \quad (5.14)$$

ritrovando in questo modo la forma (5.1) con $\mathbf{A}_0 = \mathbf{I}$; per maggiori dettagli sulle specifiche tecniche e sulle scelte dei parametri α_r si rimanda a [23]. Per gli esperimenti lo sketching è scelto come nella sezione 4.6 e la risoluzione del problema proiettato nel caso del metodo con sketching avviene con l'algoritmo BICGSTAB (per maggiori dettagli, si rimanda a [25]) il cui arresto avviene con una tolleranza di 10^{-8} . Invece per il metodo basato su spazi di Krylov razionali, la risoluzione dell'equazione del problema proiettato avviene con il metodo dei Gradienti Coniugati orientato alle matrici con tolleranza di 10^{-8} . Le specifiche tecniche della macchina sono le stesse già scritte nella sezione 4.6. I problemi test vengono dal pacchetto MATLAB S-IFISS [27]. L'Esempio 5.3.1 corrisponde al problema test 5 in S-IFISS e ha un coefficiente di diffusione della forma (5.11) usato in [10]. L'Esempio 5.3.2 corrisponde al problema test 2 di S-IFISS, e in questo caso, il coefficiente di diffusione è della forma (5.12). Lo scopo è evidenziare la differenza in termini di tempo dei due algoritmi. I criteri d'arresto per i due algoritmi sono i seguenti:

- Per il metodo sketching si valuterà il residuo con sketching $\|\mathbf{S}\mathbf{R}_d^{SK}\|_F$ dove $\mathbf{R}_d^{SK}$ è il residuo rispetto alla soluzione del problema proiettato all'iterazione d -esima.

- Per il metodo con spazi di Krylov razionali si valuterà

$$\frac{\|\mathbf{Y}_d - [\mathbf{Y}_{d-1}; 0]\|_F}{\|\mathbf{Y}_d\|_F},$$

dove $\mathbf{Y}_d$ è la soluzione del problema proiettato all'iterazione d -esima

Esempio 5.3.1. Si considera il dominio quadrato $D = [0, 1] \times [0, 1]$ e il coefficiente di diffusione come in (5.11) con:

$$a_0 = 1, \quad a_r(\vec{x}) = \gamma_r \cos(2\pi\beta_1(r)x_1) \cos(2\pi\beta_2(r)x_2),$$

dove $\gamma_r = 0.832r^{-4}$ e

$$\beta_1(r) = r - c(r)\frac{c(r+1)}{2}, \quad \beta_2(r) = c(r) - \beta_1(r),$$

con

$$c(r) = \left\lfloor -\frac{1}{2} + \frac{1}{4} + 2r \right\rfloor.$$

Le matrici $\mathbf{K}_i$ e $\mathbf{G}_i$ derivanti dalla discretizzazione di (5.10) hanno dimensione rispettivamente $n_x = 16129$ e $n_\xi = 1287$. Verranno confrontati il metodo con sketching e troncato (STKM) con il metodo basato su spazi di Krylov razionali (RKSM) al variare del numero m di termini del coefficiente di diffusione per quanto le caratteristiche della macchina consentono. I parametri fissi sono maxit=160, la dimensione delle righe dello sketching $s = 300$, la tolleranza $tol = 10^{-6}$ e il parametro di troncamento $k = 120$.

m	RKSM			STKM		
	d	res	time	d	res	time
6	257	9.88e-7	12.3	196	9.47e-7	9.07
9	312	7.37e-7	18.9	199	9.88e-7	7.96
12	295	8.03e-7	25.6	152	8.31e-7	8.11

Tabella 5.1. Prestazioni dei metodi. I tempi di CPU riportati sono in secondi. "res" indica il residuo finale e d indica la dimensione finale del relativo spazio di Krylov associato al metodo.

Come si evince dalla Tabella 5.1 il metodo con sketching è più veloce rispetto a RKSM e richiede uno spazio di dimensione minore per trovare la soluzione del problema

a differenza del metodo RKSM rendendolo così competitivo.




Figura 5.1. Storia del residuo dei due metodi per $m = 9$ (sinistra), $m = 12$ (destra). In rosso il metodo STKM e in blu RKSM

Come si evince dalla Figura 5.1, il metodo STKM converge più rapidamente rispetto al metodo RKSM.

Esempio 5.3.2. Si considera il dominio $D = [-1, 1] \times [-1, 1]$ ed il coefficiente di diffusione della forma (5.12) con media $\mu = 1$. Si considera $\xi_r \sim U(-\sqrt{3}, \sqrt{3})$ e la funzione di covarianza

$$C(\vec{x}_1, \vec{x}_2) = \sigma^2 \exp\left(-\frac{\|\vec{x}_1 - \vec{x}_2\|_1}{l}\right),$$

dove l denota la lunghezza di correlazione. In questo esempio si vuole studiare l'andamento dei due metodi STKM e RKSM al variare della dimensione n_x . Le matrici $\mathbf{G}_i$ hanno dimensione $n_\xi = 792$ e il numero di termini del coefficiente di diffusione è $m = 6$. I parametri fissi sono $maxit = 160$, la dimensione delle righe dello sketching $s = 300$, la tolleranza $tol = 10^{-6}$ e il parametro di troncamento $k = 70$.

n	RKSM			STKM		
	d	res	time	d	res	time
16129	125	5.61e-7	3.15	106	9.82e-7	3.07
65025	125	7.37e-7	8.99	106	9.42e-7	7.24
261121	125	6.10e-7	47.9	100	9.92e-7	31.4

Tabella 5.2. Prestazioni dei metodi. I tempi di CPU riportati sono in secondi. "res" indica il residuo finale e d indica la dimensione finale del relativo spazio di Krylov associato al metodo.

Come nell'esempio precedente si può notare dalla Tabella 5.2 come il metodo STKM sia più veloce in termini di tempo rispetto al metodo RKSM seppur di poco nei primi due casi. Inoltre, come nel caso precedente, STKM richiede una spazio di Krylov di dimensione minore rispetto al metodo RKSM.




Figura 5.2. Storia del residuo dei due metodi per $n = 65025$ (sinistra), $n = 261121$ (destra). In rosso il metodo STKM e in blu RKSM

Come si può vedere in Figura 5.2, il metodo STKM appare più performante all'inizio, riducendo il residuo più rapidamente rispetto a RKSM, ma entrambi i metodi convergono verso un residuo finale simile dopo un numero simile di iterazioni.

Conclusioni

Come visto durante la trattazione, la combinazione di metodi di sketching e Krylov con una schema troncato sono uno strumento promettente per la risoluzione di equazioni matriciali lineari.

Oltre a rendere efficienti i metodi polinomiali di Krylov, l'approccio si dimostra competitivo anche rispetto agli schemi all'avanguardia basati su sottospazi di Krylov razionali. In particolare, il metodo proposto riduce la domanda di memoria dell'intero processo di risoluzione e fornisce un'accelerazione del tempo rispetto a RKSM e soprattutto quando si lavora con equazioni matriciali di larga scala e con un numero di termini maggiori rispetto a quello di equazioni della forma (4.1). Pertanto, tale procedimento può essere un valido candidato per risolvere equazioni matriciali su larga scala per le quali i metodi di proiezione basati su sottospazi più sofisticati sono ostacolati, ad esempio, a causa della risoluzione costosa di sistemi lineari.

Nonostante la perdita di sparsità e di simmetria delle matrici proiettate, le equazioni lineari proiettate sono solitamente risolvibili nella pratica e gli esperimenti numerici hanno mostrato prestazioni soddisfacenti.

Appendice

Appendice A: Metodo dei Gradienti Coniugati orientato alle matrici

Sia l'equazione

$$\mathbf{A}\mathbf{X} + \mathbf{X}\mathbf{A}^\top + \mathbf{M}\mathbf{X}\mathbf{M}^\top = \mathbf{C}\mathbf{C}^\top \quad (5.15)$$

e sia la funzione matriciale:

$$\mathcal{L}(\mathbf{X}) = \mathbf{A}\mathbf{X} + \mathbf{X}\mathbf{A}^\top + \mathbf{M}\mathbf{X}\mathbf{M}^\top$$

In seguito si descrive il metodo dei gradienti coniugati orientato alle matrici:

Algorithm 6 Algoritmo CG per l'equazione matriciale (5.15)

- 1: **Input:** Funzione matrice $\mathcal{L} : \mathbb{R}^{n \times n} \rightarrow \mathbb{R}^{n \times n}$, termine noto $\mathbf{C} = \mathbf{C}\mathbf{C}^\top \in \mathbb{R}^{n \times n}$.
 - 2: **Output:** Matrice $\mathbf{X} \in \mathbb{R}^{n \times n}$ che approssima la soluzione di (6.1).
 - 3: $\mathbf{X}^{(0)} = \mathbf{O}_{n,n}$, $\mathbf{R}^{(0)} = \mathbf{C}$, $\mathbf{P}^{(0)} = \mathbf{R}^{(0)}$, $\mathbf{J}^{(0)} = \mathcal{L}(\mathbf{P}^{(0)})$
 - 4: $\xi_0 = \langle \text{vec}(\mathbf{P}^{(0)}), \text{vec}(\mathbf{J}^{(0)}) \rangle$, $k = 0$
 - 5: **while** $\|\mathbf{R}^{(k)}\|_F > \text{tol}$ **do**
 - 6: $\alpha_k = \langle \text{vec}(\mathbf{R}^{(k)}), \text{vec}(\mathbf{P}^{(k)}) \rangle / \xi_k$
 - 7: $\mathbf{X}^{(k+1)} = \mathbf{X}^{(k)} + \alpha_k \mathbf{P}^{(k)}$
 - 8: $\mathbf{R}^{(k+1)} = \mathbf{C} - \mathcal{L}(\mathbf{X}^{(k+1)})$
 - 9: $\beta_k = -\langle \text{vec}(\mathbf{R}^{(k+1)}), \text{vec}(\mathbf{J}^{(k)}) \rangle / \xi_k$
 - 10: $\mathbf{P}^{(k+1)} = \mathbf{R}^{(k+1)} + \beta_k \mathbf{P}^{(k)}$
 - 11: $\mathbf{J}^{(k+1)} = \mathcal{L}(\mathbf{P}^{(k+1)})$
 - 12: $\xi_{k+1} = \langle \text{vec}(\mathbf{P}^{(k+1)}), \text{vec}(\mathbf{J}^{(k+1)}) \rangle$
 - 13: $k = k + 1$
 - 14: **end while**
 - 15: $\mathbf{X} = \mathbf{X}^{(k)}$
-

Appendice B: Metodo basato su spazi di Krylov razionali

Algorithm 7 Solver a Base Ridotta Multitermine (MultiRB)

Require: le matrici $\{\mathbf{A}_r\}_{r=1,2,\dots,m}$ e $\{\mathbf{B}_r\}_{r=0,1,\dots,m}$, i vettori f_0 e g_0 , i parametri $s = [s_1, s_2, \dots]$, la soglia di troncamento β , e il numero massimo di iterazioni $j_{\max}$.

- 1: $v = f_0 / \|f_0\|$, $V_0 = v$, $j = 1$
 - 2: **while** non convergente e $j < j_{\max}$ **do**
 - 3: Calcola $\mathbf{W} = [(\mathbf{A}_1 + s_j \mathbf{I})^{-1}v, \dots, (\mathbf{A}_m + s_j \mathbf{I})^{-1}v]$
 - 4: Tronca $\mathbf{W} \leftarrow \text{trunc}(\mathbf{W}) \in \mathbb{R}^{n_x \times l_j}$ ed aumenta $V_j \leftarrow \text{orth}([V_{j-1}, \mathbf{W}])$
 - 5: Aggiorna le matrici proiettate $\underline{\mathbf{A}}_r = V_j^\top \mathbf{A}_r V_j$, $r = 1, \dots, m$, $\underline{f} = V_j^\top f_0$
 - 6: Risolvi approssimativamente $\mathbf{Y}_j \mathbf{B}_0 + (\underline{\mathbf{A}}_1 \mathbf{Y}_j \mathbf{B}_1 + \dots + \underline{\mathbf{A}}_m \mathbf{Y}_j \mathbf{B}_m) = \underline{f} g_0^\top$ e verifica la convergenza
 - 7: **if** il criterio di arresto è soddisfatto **then**
 - 8: Imposta $k = j$ e termina
 - 9: **else**
 - 10: Imposta $v = V_j e_{j+1}$ (usa la colonna successiva di V_j per espandere lo spazio)
 - 11: Imposta $j = j + 1$
 - 12: **end if**
 - 13: **end while**
-

Bibliografia

- [1] Nir Ailon and Bernard Chazelle. In *Approximate nearest neighbors and the fast Johnson-Lindenstrauss transform*, volume 2006, pages 557–563, 05 2006.
- [2] Sanjeev Arora, Elad Hazan, and Satyen Kale. A fast random sampling algorithm for sparsifying matrices. volume 4110, pages 272–279, 01 2006.
- [3] Ivo Babuska, Raúl Tempone, and Georgios E. Zouraris. Galerkin finite element approximations of stochastic elliptic partial differential equations. *SIAM Journal on Numerical Analysis*, 42(2):800–825, 2004.
- [4] Oleg Balabanov and Laura Grigori. Randomized block Gram-Schmidt process for solution of linear systems and eigenvalue problems, 2023. arXiv preprint {arXiv:2111.14641}.
- [5] Liam Burke and Stefan Güttel. Krylov Subspace Recycling With Randomized Sketching For Matrix Functions. *SIAM Journal on Matrix Analysis and Applications*, 2024. arXiv preprint arXiv:2308.02290.
- [6] Alice Cortinovis, Daniel Kressner, and Yuji Nakatsukasa. Speeding up Krylov Subspace Methods for Computing $f(A)b$ via Randomization. *SIAM Journal on Matrix Analysis and Applications*, 45(1):619–633, 2024.
- [7] Manas K. Deb, Ivo M. Babuška, and J.Tinsley Oden. Solution of stochastic partial differential equations using Galerkin finite element techniques. *Computer Methods in Applied Mechanics and Engineering*, 190(48):6359–6372, 2001.
- [8] Petros Drineas, Michael W. Mahoney, and S. Muthukrishnan. Sampling algorithms for l_2 regression and applications. In *Proceedings of the Seventeenth Annual ACM-SIAM Symposium on Discrete Algorithm*, SODA '06, page 1127–1136, USA, 2006. Society for Industrial and Applied Mathematics.

- [9] Petros Drineas, Michael W. Mahoney, S. Muthukrishnan, and Tamás Sarlós. Faster least squares approximation. *CoRR*, abs/0710.1435, 2007.
- [10] Martin Eigel, Claude Jeffrey Gittelsohn, Christoph Schwab, and Elmar Zander. Adaptive stochastic Galerkin FEM. *Computer Methods in Applied Mechanics and Engineering*, 270:247–269, 2014.
- [11] Uriel Feige and Eran Ofek. Spectral techniques applied to sparse random graphs. *Random Structures and Algorithms*, 27, 09 2005.
- [12] Stefan Güttel and Marcel Schweitzer. Randomized Sketching for Krylov Approximations of Large-Scale Matrix Functions. *SIAM Journal on Matrix Analysis and Applications*, 44:1073–1095, 07 2023.
- [13] Piotr Indyk and Rajeev Motwani. Approximate nearest neighbors: towards removing the curse of dimensionality. In *Proceedings of the Thirtieth Annual ACM Symposium on Theory of Computing*, STOC '98, page 604–613, New York, NY, USA, 1998. Association for Computing Machinery.
- [14] P. Lancaster and M. Tismenetsky. *The Theory of Matrices: With Applications*. Computer Science and Scientific Computing. Elsevier Science, 1985.
- [15] Peter Lancaster. Explicit solutions of linear matrix equations. *SIAM Review*, 12(4):544–566, 1970.
- [16] Gabriel J. Lord, Catherine E. Powell, and Tony Shardlow. *An Introduction to Computational Stochastic PDEs*. Cambridge Texts in Applied Mathematics. Cambridge University Press, 2014.
- [17] Avner Magen. Dimensionality Reductions in l_2 that Preserve Volumes and Distance to Affine Spaces. *Discrete Computational Geometry*, 38:139–153, 07 2007.
- [18] J. Matousek. *Lectures on Discrete Geometry*. Graduate Texts in Mathematics. Springer New York, 2013.
- [19] Yuji Nakatsukasa and Joel A. Tropp. Fast & Accurate Randomized Algorithms for Linear Systems and Eigenvalue Problems. *SIAM Journal on Matrix Analysis and Applications*, 43(4):1613–1645, 2022.
- [20] Davide Palitta, Marcel Schweitzer, and Valeria Simoncini. Sketched and Truncated Polynomial Krylov Methods: Evaluation of Matrix Functions, 2023. arXiv

preprint 2306.06481.

- [21] Davide Palitta, Marcel Schweitzer, and Valeria Simoncini. Sketched and Truncated Polynomial Krylov Subspace Methods: Matrix Sylvester Equations, 2024. arXiv preprint 2311.16019.
- [22] Davide Palitta and Valeria Simoncini. Optimality Properties of Galerkin and Petrov-Galerkin Methods for Linear Matrix Equations. *SIAM Journal on Matrix Analysis and Applications*, 40(2):595–621, 2019.
- [23] C. E. Powell, D. Silvester, and V. Simoncini. An Efficient Reduced Basis Solver for Stochastic Galerkin Matrix Equations. *SIAM Journal on Scientific Computing*, 39(1):A141–A163, 2017.
- [24] Catherine E. Powell and Howard C. Elman. Block-diagonal preconditioning for spectral stochastic finite-element systems. *IMA Journal of Numerical Analysis*, 29(2):350–375, April 2009.
- [25] Y. Saad. *Iterative Methods for Sparse Linear Systems*. Society for Industrial and Applied Mathematics, 2003.
- [26] Tamas Sarlos. Improved approximation algorithms for large matrices via random projections. In *2006 47th Annual IEEE Symposium on Foundations of Computer Science (FOCS'06)*, pages 143–152, 2006.
- [27] D.J. Silvester, A. Bespalov, and C.E. Powell. S-ifiss version 1.02, July 2015. <http://www.manchester.ac.uk/ifiss/s-ifiss1.0.tar.gz>.
- [28] V. Simoncini. Computational methods for linear matrix equations. *SIAM Review*, 58:377–441, 01 2016.
- [29] Valeria Simoncini and Yue Hao. Analysis of the truncated conjugate gradient method for linear matrix equations. *SIAM Journal on Matrix Analysis and Applications*, 44(1):359–381, 2023.
- [30] Valeria Simoncini and Daniel Szyld. The effect of non-optimal bases on the convergence of Krylov subspace methods. *Numerische Mathematik*, 100:711–733, 06 2005.
- [31] Joel A. Tropp. Improved Analysis of the Subsampled Randomized Hadamard Transform. *Advances in Adaptive Data Analysis*, 3(1-2):115–126, 2011.

- [32] David P. Woodruff. Sketching as a Tool for Numerical Linear Algebra. *Foundations and Trends in Theoretical Computer Science*, 10(1-2):1–157, 2014.